

# Perbandingan Metoda K-NN, Random Forest dan 1D CNN untuk Mengklasifikasi Data EEG Eye State

Muhammad Ibnu Choldun Rachmatullah\*, Aryaputra Wicaksono, Viridiandry Putratama

Sekolah Vokasi, D3 Manajemen Informatika, Universitas Logistik dan Bisnis Internasional, Bandung

Jl. Sari Asih No.54, Kota Bandung, Jawa Barat, Indonesia

Email: <sup>1,\*</sup>muhammadibnucholdun@ulbi.ac.id, <sup>2</sup>aryaptra@gmail.com, <sup>3</sup>viridiandry@ulbi.ac.id

Email Penulis Korespondensi: muhammadibnucholdun@ulbi.ac.id

Submitted: 21/01/2023; Accepted: 31/01/2023; Published: 31/01/2023

**Abstrak**—Penggunaan metode pembelajaran mesin/machine learning sangat penting dalam mengembangkan identifikasi status mata manusia, khususnya hal pemrosesan sinyal Electroencephalogram (EEG) untuk mengidentifikasi status mata. Pada penelitian terdahulu metode yang digunakan dapat merupakan metode kombinasi antara supervised learning dan unsupervised learning, maupun metode tunggal yang menggunakan supervised learning. Pada penelitian ini pengklasifikasian EEG Eye State menggunakan metode tunggal dengan supervised learning yaitu menggunakan metode: K-nearest neighbors (k-NN), random forest, dan 1D Convolutional Neural Networks (1D CNNs). Kinerja dari ketiga metoda pengklasifikasi tersebut diukur dengan menggunakan empat ukuran, yaitu: akurasi, recall, presisi, dan F1-Score. Dari hasil eksperimen didapatkan hasil bahwa metode k-NN mempunyai kinerja terbaik dibanding dua metode lainnya dilihat dari empat ukuran yang digunakan, di mana nilai masing-masing ukuran tersebut adalah: akurasi=82,30%; recall=82,30%; presisi= 82,36%; dan F1-Score=82,30%. K-NN lebih cocok untuk mengklasifikasi EEG Eye State dibanding dua metode lainnya, karena semua atribut input dari dataset mempunyai tipe data bilangan riil.

**Kata Kunci:** Klasifikasi; EEG Eye State; k-NN; Random Forest; 1D CNN

**Abstract**—The use of machine learning / machine learning methods is very important in developing identification of the status of the human eye, especially in terms of processing Electroencephalogram (EEG) signals to identify eye status. In previous research the method used can be a combination method between supervised learning and unsupervised learning, or a single method using supervised learning. In this study, the EEG Eye State classification uses a single method with supervised learning, namely using the following methods: K-nearest neighbors (k-NN), random forest, and 1D Convolutional Neural Networks (1D CNNs). The performance of the three classifier methods is measured using four measures, namely: accuracy, recall, precision, and F1-Score. From the experimental results it was found that the k-NN method has the best performance compared to the other two methods in terms of the four measures used, where the value of each measure is: accuracy = 82.30%; recall=82.30%; precision= 82.36%; and F1-Score=82.30%. K-NN is more suitable for classifying EEG Eye State than the other two methods, because all input attributes are from the dataset. has a data type of real numbers.

**Keywords:** Classification; EEG Eye State; k-NN; Random Forest; 1D CNN

## 1. PENDAHULUAN

Terdapat area penelitian di bidang interaksi manusia-komputer/ human-computer interaction (HCI) yaitu, antarmuka komputer otak/ brain computer interface (BCI) yang memiliki rentang yang luas, seperti bidang-bidang: security supervision, critical safety, dan aplikasi di industri dan obat-obatan. Hal ini cukup penting dalam aplikasi kedokteran; misalnya, para penyandang cacat dapat berinteraksi lebih baik dengan memanfaatkan cara ini, yang dapat dicapai dengan menemukan metode yang bertindak seperti perantara atau penghubung antara komputer dan otak manusia. Electroencephalogram (EEG) berkaitan dengan sinyal yang diterima secara elektrik dari aktivitas otak. Hal ini dianggap sebagai hasil dari aliran data selama pertukaran informasi dari banyak neuron dan dapat direkam untuk waktu yang lama [1].

Banyak peneliti telah melakukan penelitian berkaitan dengan klasifikasi sinyal EEG. Rafie dkk. meneliti tentang gangguan depresi mayor/ major depressive disorder (MDD) yang dianggap sebagai penyakit parah dan mempunyai efek kelemahan fungsional, sementara manifestasinya yang jelas belum diketahui. Oleh karena itu, deteksi MDD secara manual adalah tugas yang menantang dan subyektif. Meskipun sinyal Electroencephalogram (EEG) telah menjanjikan dalam membantu diagnosis, peningkatan lebih lanjut diperlukan untuk meningkatkan akurasi, utilitas klinis, dan efisiensi. Studi ini berfokus pada deteksi otomatis MDD menggunakan data EEG dan menggunakan arsitektur deep neural network [2]. Safira dkk meneliti tentang prediksi hasil cedera otak traumatis/ traumatic brain injury (TBI) berdasarkan pembelajaran yang berasal EEG. Namun demikian, pendekatan tersebut telah menderita dari kumpulan data yang tidak seimbang. Oleh karena itu, untuk mendapatkan model prediksi yang andal untuk memprediksi hasil, khususnya dalam proporsi TBI sedang yang tinggi dengan hasil yang baik, dapat menjadi tantangan. Penelitian ini mengusulkan model prediksi hasil yang ditingkatkan yang menggabungkan power spectral density (PSD) absolut sebagai fitur input untuk melatih random under-sampling boosting decision trees (RUSBoosted Trees) sebagai pengklasifikasi [3]. Mahmood dkk. meneliti dengan tujuan menyelidiki perubahan konektivitas fungsional otak/ functional connectivity (FC) ketika musik digunakan sebagai stimulus. Kedua, efek mendengarkan musik favorit subjek dibandingkan dengan mendengarkan musik santai yang diformulasikan secara khusus dengan alfa binaural beats. Terakhir, efek durasi mendengarkan musik dipelajari. Sinyal elektroensefalografik (EEG) subjek ditangkap saat mereka mendengarkan musik favorit dan menenangkan.

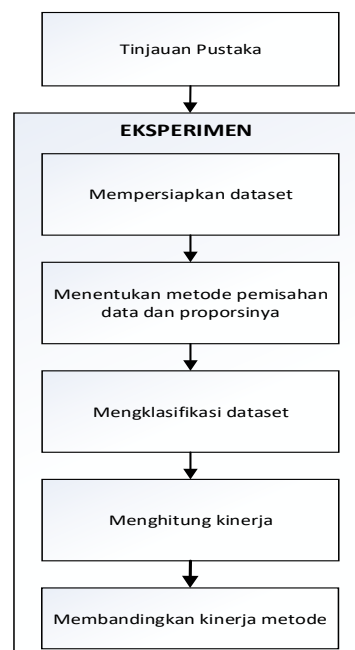
Setelah preprocessing rekaman EEG didekomposisi menjadi pita frekuensi delta, theta, alfa, dan beta, dan matriks konektivitas rata-rata besar dihasilkan menggunakan Inter-Site Phase Clustering (ISPC) untuk setiap pita frekuensi dan setiap jenis musik [4]. Cooney dkk. menyatakan bahwa klasifikasi sinyal elektroensefalografi (EEG) yang sesuai dengan produksi ucapan yang dibayangkan penting untuk pengembangan antarmuka sebuah direct-speech brain-computer interface (DS-BCI). Dalam penelitian ini bertujuan untuk meningkatkan klasifikasi EEG dari ucapan imajiner (imagined speech) dengan menggunakan metode deep learning dan juga mengevaluasi secara statistik dampak pengoptimalan hiperparameter pada kinerja pengklasifikasi [5]. Laport dkk. melakukan penelitian untuk mendeteksi status mata yang mewakili pola aktivitas dalam ritme otak dengan mempertimbangkan perangkat EEG dengan dua sensor dan teknik berbeda untuk ekstraksi fitur, seperti Independent Component Analysis (ICA), Discrete Wavelet Transform (DWT) dan Discrete Fourier Transform (DFT). Selain itu, dua pengklasifikasi untuk EEG seperti Support Vector Machine (SVM) dan Linear Discriminant Analysis (LDA) juga diuji dan dievaluasi [6]. Zhou dkk. melakukan penelitian untuk mengembangkan automatic sleep staging system, yang menggunakan sinyal elektroensefalogram (EEG) saluran tunggal, untuk kenyamanan pemakaian dan mengurangi gangguan pada tidur, untuk melakukan identifikasi otomatis berbagai tahapan tidur. Untuk mencapai automatic sleep staging system, penelitian ini mengusulkan model ensemble dua tingkat, yang menggabungkan keunggulan random forest (RF) dan LightGBM (LGB), di mana RF berfokus pada pengurangan varian model yang diusulkan sementara LGB berfokus pada mengurangi bias dari model yang diusulkan [7].

Penggunaan metode pembelajaran mesin sangat penting dalam mengembangkan identifikasi status mata manusia. Dalam hal pemrosesan sinyal EEG untuk mengidentifikasi status mata, penerapan pendekatan pembelajaran mesin yang diawasi (supervised learning) dan tidak diawasi (unsupervised learning) telah menjadi unggulan dan kontribusinya dalam analisis EEG sangat berarti. Seperti dalam sistem status identifikasi mata, prediksi status mata sangat penting, memilih metode pembelajaran mesin terawasi dan tanpa pengawasan yang tepat memainkan peran penting dalam meningkatkan akurasi dan kecepatan sistem. Dalam penelitian sebelumnya, teknik yang dikembangkan untuk identifikasi status mata berdasarkan sinyal EEG sebagian besar mengandalkan satu pendekatan pembelajaran, namun ada juga yang melalui kombinasi teknik pembelajaran, seperti teknik pembelajaran terawasi dan tidak terawasi [8]. Selain itu, pendekatan pembelajaran mendalam (deep learning) telah menunjukkan keefektifannya dalam analisis EEG [9] [10] [11] [12]. Selain menggunakan kombinasi teknik pembelajaran ataupun deep learning, ada juga yang menggunakan metode tunggal misalnya penelitian yang menggunakan Support Vector Machine (SVM) [13].

Pada penelitian ini pengklasifian sinyal EEG untuk identifikasi status mata menggunakan teknik pembelajaran tunggal dengan tiga metode yang berbeda, yaitu: k-NN, random forest, dan 1D Convolutional Neural Networks (1D CNNs). Kinerja dari ketiga metode tersebut diukur dengan menggunakan nilai: akurasi, recall, presisi, dan F1-Score dan kemudian dibandingkan.

## 2. METODOLOGI PENELITIAN

Metodologi penelitian berupa langkah-langkah penelitian yang terdiri dari dua langkah utama yaitu tinjauan pustaka dan eksperimen seperti terlihat pada gambar 1.



**Gambar 1.** Langkah-Langkah Penelitian

Tinjauan pustaka membahas tentang k-NN, random forest, dan 1D CNN. Tahapan eksperimen meliputi: mempersiapkan dataset, menentukan metode pemisahan data dan proporsinya, mengklasifikasi dataset, menghitung kinerja, dan membandingkan kinerja metode. Masing-masing langkah dijelaskan seperti berikut ini

## 2.1 Tinjauan Pustaka

Metode pengklasifikasi yang dibandingkan dalam penelitian ini adalah: K-NN, random forest, dan 1D CNN. Masing-masing dijelaskan secara ringkas dalam uraian berikut ini.

### 2.1.1 K-Nearest Neighbors (K-NN)

K-nearest neighbors (k-NN) adalah teknik untuk melakukan klasifikasi berbasis data pembelajaran, dengan cara mengambil k tetangga paling dekat (nearest-neighbors) [14]. Banyaknya data dan jumlah dimensi data yang dimiliki berpengaruh pada penentuan jumlah k tetangga. Jarak antara satu titik dengan titik tetangga terdekat dapat dihitung dengan menggunakan rumus jarak Euclidean sebagaimana terlihat dibawah ini :

$$D(x,y) = \sqrt{\sum_{k=1}^n (a_k - b_k)^2} \quad (1)$$

a = titik dengan kelas yang sudah diketahui, b = titik baru, dan D = Jarak. D(x,y) adalah jarak antara titik yang telah diketahui klasifikasinya (a) dan titik baru (b). Jarak antara titik baru dengan titik data pelatihan akan dihitung dan ditentukan jumlah tetangga (k) dalam analisis.

### 2.1.2 Random Forest

Random forest adalah salah satu teknik yang berbasis pada kumpulan decision tree. Teknik ini membangun pohon keputusan mulai dari simpul akar sampai simpul daun dengan mengambil atribut secara acak [15]. Metode yang menggunakan pohon keputusan yang terdiri dari simpul akar (root node), simpul internal (internal node), dan simpul daun (leaf node) [16]. Langkah-langkah dari random forest adalah sebagai berikut:

- Menentukan jumlah pohon/tree (k) yang dipilih dari total fitur m, di mana k kurang dari m.
- Mengambil sampel sejumlah N pada dataset untuk setiap pohon.
- Pada setiap pohon, lakukan pengambilan subset prediktor sebanyak m secara acak, dimana  $m < p$ , p adalah jumlah variabel prediktor.
- Ulangi langkah kedua dan ketiga sampai pohon sebanyak k.
- Hasil prediksi diperoleh dari vote terbanyak dari hasil klasifikasi sebanyak k pohon.

### 2.1.3 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) telah banyak digunakan dalam berbagai aplikasi, seperti pengenalan gambar dan video, analisis citra medis, pemrosesan bahasa alami, dan pengenalan suara. CNN cocok untuk menganalisis data dengan ketergantungan spasial atau temporal antar komponen. Meskipun CNN telah diterapkan untuk analisis gambar dengan sangat sukses, data non-gambar di berbagai bidang, seperti bioinformatika, kedokteran, keuangan, dan lain-lain, di mana CNN mungkin tidak dapat diterapkan secara langsung untuk mengambil kelebihan dari CNN yang dapat mengenali keterhubungan spasial atau temporal. Misalnya untuk dataset tabular, di mana umumnya antar fitur tidak mempunyai keterhubungan secara spasial maupun temporal, beberapa peneliti melakukan transformasi ulang data dengan mengubah data tabular satu dimensi menjadi data dengan dua dimensi, misal ditransformasi menjadi matriks dua dimensi ataupun ditransformasi menjadi gambar dua dimensi. Urutan fitur dapat diatur ulang dalam ruang 2D untuk secara eksplisit mewakili hubungan antara fitur, seperti kategori fitur atau kesamaan. Akhir-akhir ini, selain CNN yang memproses data dua dimensi, juga dikembangkan CNN yang dapat memproses data satu dimensi, dan biasa disebut dengan 1D Convolutional Neural Networks (1D CNNs) [17] [18].

## 2.2 Mempersiapkan Dataset

Dataset yang digunakan diambil dari UCI Machine Learning Repository yang mempunyai fungsi tujuan klasifikasi dua kelas. Dataset yang digunakan yaitu EEG Eye State yang terdiri dari 14980 data, mempunyai 14 atribut input, sedangkan atribut outputnya berupa pengklasifikasi yang terdiri dari 2 kelas [19].

## 2.3 Menentukan Metode Pemisahan Data dan Proporsinya

Metode pemisahan data yang digunakan adalah splitting yaitu membagi data menjadi dua bagian, yaitu untuk pelatihan (training) dan untuk pengujian (testing) dengan proporsi tertentu. Proporsi pembagian yang optimal untuk pelatihan dan pengujian adalah masing-masing 70-80% untuk pelatihan dan 20-30% untuk pengujian [20]. Proporsi yang digunakan dalam penelitian ini adalah 70% data untuk pelatihan dan 30% data untuk pengujian.

## 2.4 Mengklasifikasi Dataset

Metode pengklasifikasi yang dipakai pada penelitian ini ada tiga, yaitu:

- k-NN
- Random forest

c. 1D CNN.

## 2.5 Menghitung Kinerja

Untuk mengevaluasi kinerja algoritma pembelajaran mesin menggunakan panduan dari Confusion Matrix. Confusion Matrix merepresentasikan prediksi dan kondisi sebenarnya (aktual) dari data yang dihasilkan oleh metode pembelajaran mesin yang dapat dilihat pada tabel 1.

**Tabel 1.** Confusion Matrix

	Nilai Aktual	
	Positif (1)	Negatif (0)
Positif (1)	TP	FP
Negatif (1)	FN	TN

Berdasarkan Confusion Matrix, dapat ditentukan nilai akurasi, recall, dan presisi. F1-Score ditentukan dengan membandingkan nilai presisi dan recall. Kinerja dari masing-masing metode pengklasifikasi yang digunakan dihitung berdasar nilai akurasi, recall, presisi, dan F1-Score [21] [22]. Akurasi adalah prosentase banyaknya data yang diprediksi dengan benar terhadap jumlah keseluruhan data. Recall adalah seberapa andal (dinyatakan dalam persen) suatu model dapat memprediksi data yang mempunyai label positif dengan benar. Presisi merupakan rasio prediksi benar positif dibandingkan dengan keseluruhan hasil yang diprediksi positif. F1-Score adalah merupakan perbandingan rata-rata presisi dan recall yang dibobotkan. Rumus untuk menghitung masing-masing kinerja disajikan pada tabel 2.

**Tabel 2.** Rumus Ukuran Kinerja

Kinerja	Rumus
Akurasi	$(TP+TN)/(TP+FP+FN+TN)$
Recall	$(TP)/(TP+FN)$
Presisi	$(TP)/(TP+FP)$
F1-Score	$2*(recall*presisi)/(recall+presisi)$

## 2.6 Membandingkan Kinerja Metode

Untuk membandingkan kinerja metode/ algoritma pembelajaran mesin maka dibandingkan ukuran kinerja dari masing-masing metode yang dilihat dari nilai akurasi, recall, presisi, dan F1-Score. Dari perbandingan ini dapat diketahui metode mana yang paling bagus untuk masing-masing ukuran kinerja.

# 3. HASIL DAN PEMBAHASAN

Bagian pembahasan berisi hasil dan analisis dari eksperimen pengklasifikasian EEG Eye State yang diklasifikasi dengan menggunakan k-NN, Random Forest, dan 1D CNN. Untuk masing-masing metode pengklasifikasi ukuran kinerjanya yang digunakan adalah akurasi, recall, presisi, dan F1-Score. Eksperimen yang dilakukan terhadap masing-masing metoda diulang sebanyak 10 kali, dan kemudian dicari nilai reratanya.

## 3.1 K-NN

Hasil eksperimen dengan menggunakan metode k-NN dapat dilihat pada tabel 3.

**Tabel 3.** Kinerja k-NN

No	Akurasi	Recall	Presisi	F1-Score
1	0,817	0,817	0,818	0,817
2	0,832	0,832	0,832	0,832
3	0,828	0,828	0,831	0,828
4	0,826	0,826	0,826	0,826
5	0,817	0,817	0,817	0,817
6	0,824	0,824	0,825	0,824
7	0,822	0,822	0,822	0,822
8	0,82	0,82	0,82	0,82
9	0,826	0,826	0,827	0,826
10	0,818	0,818	0,818	0,818
<b>Rerata</b>	<b>0,823</b>	<b>0,823</b>	<b>0,824</b>	<b>0,823</b>

Berdasarkan tabel 3 di atas masing-masing ukuran kinerja mempunyai nilai yang mirip yaitu antara nilai 82,3% sampai 82,4%. Hal ini terjadi karena dataset yang digunakan hanya terdiri dari dua kelas dan datasetnya adalah data yang seimbang (tidak termasuk dalam kategori data tidak seimbang/imbalanced data).

### 3.2 Random Forest

Hasil eksperimen dengan menggunakan metode random forest dapat dilihat pada tabel 4.

**Tabel 4.** Kinerja Random Forest

No	Akurasi	Recall	Presisi	F1-Score
1	0,676	0,676	0,678	0,676
2	0,665	0,665	0,668	0,665
3	0,689	0,689	0,691	0,689
4	0,682	0,682	0,683	0,682
5	0,674	0,674	0,676	0,674
6	0,686	0,686	0,687	0,686
7	0,678	0,678	0,678	0,678
8	0,679	0,679	0,682	0,679
9	0,672	0,672	0,672	0,672
10	0,658	0,658	0,66	0,658
<b>Rerata</b>	<b>0,676</b>	<b>0,676</b>	<b>0,678</b>	<b>0,676</b>

Berdasarkan tabel 4 di atas masing-masing ukuran kinerja mempunyai nilai yang mirip yaitu antara nilai 67,6% sampai 67,8 %. Hal ini terjadi karena dataset yang digunakan hanya terdiri dari dua kelas dan datasetnya adalah data yang seimbang (tidak termasuk dalam kategori data tidak seimbang/imbalanced data).

### 3.3 1D CNN

Arsitektur CNN yang digunakan pada penelitian ini terdiri dari satu layer convolutional dengan 64 neuron dan satu full connected layer dengan jumlah neuron adalah 16. Hasil eksperimen dengan menggunakan metode 1D CNN dapat dilihat pada tabel 5.

**Tabel 5.** Kinerja 1D CNN

No	Akurasi	Recall	Presisi	F1-Score
1	0,541	0,541	0,522	0,38
2	0,544	0,544	0,296	0,384
3	0,551	0,551	0,304	0,392
4	0,553	0,553	0,753	0,394
5	0,546	0,546	0,752	0,386
6	0,543	0,543	0,295	0,383
7	0,557	0,557	0,31	0,398
8	0,549	0,549	0,302	0,39
9	0,55	0,55	0,303	0,39
10	0,551	0,551	0,753	0,392
<b>Rerata</b>	<b>0,549</b>	<b>0,549</b>	<b>0,459</b>	<b>0,389</b>

Berdasarkan tabel 5 di atas masing-masing ukuran kinerja adalah sebagai berikut: akurasi=54,9%, recall=54,9%, presisi=45,9%, dan F1-Score=38,9%. Berbeda dengan kedua metoda terdahulu yaitu k-NN dan random forest yang keempat ukuran kinerja nilai yang mirip, dengan menggunakan 1D CNN ternyata mempunyai nilai yang bervariasi. Hal karena disebabkan dengan menggunakan 1D CNN nilai kinerja yang diperoleh tergantung dari ketepatan memilih jumlah layer maupun jumlah neuron pada tiap layer.


### 3.4 Perbandingan Kinerja

Untuk perbandingan kinerja antar ketiga metode yang digunakan digunakan nilai rata-rata dari masing-masing ukuran kinerja seperti dapat dilihat pada tabel 6 dan disajikan dalam bentuk gambar seperti terlihat pada gambar 3.

**Tabel 6.** Perbandingan Kinerja

Kinerja	k-NN	Random Forest
Akurasi	82,30%	67,59%
Recall	82,30%	67,59%
Presisi	82,36%	67,75%
F1-Score	82,30%	67,59%





**Gambar 2.** Perbandingan Kinerja

Berdasarkan tabel 6 dan gambar 2 dapat dilihat bahwa untuk mengklasifikasi dataset EEG Eye State menjadi dua kelas, ternyata metode k-NN mempunyai kinerja terbaik dibanding metode random forest maupun 1D CNN baik dari sisi akurasi, recall, presisi, maupun F1-Score dengan masing-masing nilai adalah: 82,30%; 82,30%; 82,36%; dan 82,30%. Metode dengan kinerja paling buruk adalah metode 1D CNN dengan nilai kinerja untuk akurasi, recall, presisi, maupun F1-Score dengan masing-masing nilai adalah: 54,85%; 54,85%; 45,90%; dan 38,89%. Kinerja metode k-NN lebih baik dari dua metode lainnya, karena k-NN cocok untuk mengolah dataset yang mempunyai atribut input bertipe data bilangan riil. Pada dataset EEG Eye State dari 14 atribut input bertipe bilangan riil, sehingga dapat dipahami mengapa metode k-NN lebih cocok untuk mengklasifikasi dataset tersebut dibandingkan metode random forest maupun 1D CNN.

## 4. KESIMPULAN

Penggunaan metode pembelajaran mesin sangat penting dalam mengembangkan identifikasi status mata manusia, misalnya untuk pemrosesan pengklasifikasian sinyal EEG untuk mengidentifikasi status mata. Pada penelitian ini metoda pengklasifikasi yang digunakan adalah tiga metode supervised learning tunggal yaitu: k-NN, random forest, dan 1D CNN. Dari hasil eksperimen didapatkan hasil bahwa metode k-NN mempunyai kinerja terbaik dibanding dua metode lainnya dilihat dari empat ukuran yang digunakan, di mana nilai masing-masing ukuran tersebut adalah: akurasi=82,30%; recall=82,30%; presisi= 82,36%; dan F1-Score=82,30%. K-NN lebih cocok untuk mengklasifikasi EEG Eye State dibanding dua metode lainnya, karena semua atribut input dari dataset mempunyai tipe data bilangan riil. Untuk meningkatkan kinerja dari metode tunggal, pada penelitian mendatang metode yang digunakan dapat berupa metode gabungan dari beberapa metode tunggal atau sering disebut dengan ensemble learning.

## UCAPAN TERIMA KASIH

Penulis ucapkan terima kasih kepada para dosen dan mahasiswa program studi D3 Manajemen Informatika Universitas Logistik dan Bisnis Internasional sehingga penelitian dan artikel ini dapat diselesaikan.

## REFERENCES

- [1] W. Mumtaz et al., "Biomedical Signal Processing and Control Electroencephalogram ( EEG ) -based computer-aided technique to diagnose major depressive disorder ( MDD ) &," Biomed. Signal Process. Control, vol. 31, no. 2017, pp. 108–115, 2020, doi: 10.1016/j.bspc.2016.07.006.
- [2] A. Rafiei, R. Zahedifar, and C. Sitaula, "Automated Detection of Major Depressive Disorder With EEG Signals : A Time Series Classification Using Deep Learning," IEEE Access, vol. 10, no. July, pp. 73804–73817, 2022, doi: 10.1109/ACCESS.2022.3190502.
- [3] N. O. R. Safira et al., "Improving Outcome Prediction for Traumatic Brain Injury From Imbalanced Datasets Using RUSBoosted Trees on Electroencephalography Spectral Power," IEEE Access, vol. 9, pp. 121608–121631, 2021, doi: 10.1109/ACCESS.2021.3109780.
- [4] D. Mahmood, H. Nisar, V. V. Yap, and C. Tsai, "The Effect of Music Listening on EEG Functional Connectivity of Brain : A Short-Duration and Long-Duration Study," Mathematics, vol. 10, 2022.
- [5] C. Cooney, A. Korik, and D. Coyle, "Evaluation of Hyperparameter Optimization in," Sensors, vol. 20, 2020.
- [6] F. Laport, P. M. Castro, A. Dapena, F. J. Vazquez-araujo, and D. Iglesia, "Study of Machine Learning Techniques for

- EEG Eye State Detection †,” Proceedings, vol. 54, no. 53, pp. 53–55, 2020, doi: 10.3390/proceedings2020054053.
- [7] J. Zhou, G. Wang, J. Liu, and D. Wu, “Automatic Sleep Stage Classification With Single Channel EEG Signal Based on Two-Layer Stacked Ensemble Model,” pp. 57283–57297, 2020.
  - [8] N. Ahmadi et al., “Eye State Identification Utilizing EEG Signals : A Combined Method Using Self-Organizing Map and Deep Belief Network,” vol. 2022, 2022.
  - [9] H. Dose, J. S. Muller, H. K. Iversen, and S. Puthusserypady, “An End-to-end Deep Learning Approach to MI-EEG Signal Classification for BCIs,” Expert Syst. Appl., 2018, doi: 10.1016/j.eswa.2018.08.031.
  - [10] E. Santamaría-vázquez, V. Martínez-cagigal, and S. Pérez-velasco, “Computer Methods and Programs in Biomedicine Robust asynchronous control of ERP-Based brain-Computer interfaces using deep learning,” vol. 215, 2022, doi: 10.1016/j.cmpb.2022.106623.
  - [11] S. Manikandan, “A Deep Learning approach for automatic classification of Cognitive Task using the scalp Electroencephalogram signals A Deep Learning approach for automatic classification of Cognitive Task using the scalp Electroencephalogram signals,” no. February, 2021.
  - [12] Y. R. Tabar and U. Halici, “A novel deep learning approach for classification of EEG motor imagery signals,” J. Neural Eng., p. 16003, doi: 10.1088/1741-2560/14/1/016003.
  - [13] I. Kayadibi, G. Emre, G. Uçman, E. Nurgül, and Ö. Süzme, “An Eye State Recognition System Using Transfer Learning : AlexNet - Based Deep Convolutional Neural Network,” Int. J. Comput. Intell. Syst., vol. 2, 2022, doi: 10.1007/s44196-022-00108-2.
  - [14] A. Naimi, J. Deng, and S. Member, “Fault Detection and Isolation of a Pressurized Water Reactor Based on Neural Network and K-Nearest Neighbor,” IEEE Access, vol. 10, pp. 17113–17121, 2022.
  - [15] I. F. Yulianti and P. R. Sihombing, “Penerapan Metode Machine Learning dalam Klasifikasi Risiko Kejadian Berat Badan Lahir Rendah di Indonesia Implementation of Machine Learning Method in Risk Classification on Low Birth weight in Indonesia,” Matrik J. Manajemen, Tek. Inform. dan Rekayasa Komput., vol. 20, no. 2, pp. 417–426, 2021, doi: 10.30812/matrik.v20i2.1174.
  - [16] U. Erdiansyah, A. I. Lubis, and K. Erwansyah, “Komparasi Metode K-Nearest Neighbor dan Random Forest Dalam Prediksi Akurasi Klasifikasi Pengobatan Penyakit Kutil,” J. MEDIA Inform. BUDIDARMA, vol. 6, pp. 208–214, 2022, doi: 10.30865/mib.v6i1.3373.
  - [17] S. Kiranyaz, O. Avci, O. Abdeljaber, T. Ince, M. Gabbouj, and D. J. Inman, “1D convolutional neural networks and applications : A survey,” Mech. Syst. Signal Process., vol. 151, p. 107398, 2021, doi: 10.1016/j.ymssp.2020.107398.
  - [18] G. Lu, Y. Wang, H. Yang, and J. Zou, “One-dimensional convolutional neural networks for acoustic waste sorting,” J. Clean. Prod., p. 122393, 2020, doi: 10.1016/j.jclepro.2020.122393.
  - [19] M. S. T. Putra and Y. Azhar, “Perbandingan Model Logistic Regression dan Artificial Neural Network pada Prediksi Pembatalan Hotel,” JISKA (Jurnal Inform. Sunan Kalijaga), vol. 6, no. 1, p. 29, 2021, doi: 10.14421/jiska.2021.61-04.
  - [20] Q. H. Nguyen et al., “Influence of Data Splitting on Performance of Machine Learning Models in Prediction of Shear Strength of Soil,” vol. 2021, 2021.
  - [21] R. Indransyah et al., “Klasifikasi Sentimen Pergelaran Motogp Di Indonesia Menggunakan Algoritma Correlated Naïve Bayes Clasifier,” pp. 60–66, 2022.
  - [22] A. Nabillah, S. Alam, and M. G. Resmi, “Twitter User Sentiment Analysis Of TIX ID Applications Using Support Vector Machine Algorithm,” vol. 3, no. 1, pp. 14–27, 2022.