

paperlbnu53919-75676667880-1-PB.pdf



Pemodelan Perkembangan *New Cases Covid-19* di Indonesia Menggunakan *Multi-Layer Perceptron* dan *Support Vector Machine*

Muhammad Ibnu Choldun Rachmatullah^{#1}

^{#D3} Manajemen Informatika, Politeknik Pos Indonesia
Jl. Sariasih No 54, Bandung

¹ibnucholdun@poltekpos.ac.id

Abstrak— Meningkatnya ketersediaan data historis dalam jumlah besar dan kebutuhan untuk membuat perkiraan yang akurat tentang perilaku masa depan menjadi perhatian khusus dalam mencari teknik yang dapat menarik kesimpulan dari mengamati hubungan antara data tertentu, antara data masa lalu dan data masa depan. Domain peramalan mengalami peningkatan sejak tahun 1960-an, dengan metode statistik linier, misalnya menggunakan model ARIMA. Baru-baru ini, model pembelajaran mesin telah menarik perhatian dan dapat digunakan sebagai teknik lain selain model statistik klasik untuk kasus peramalan. Penelitian ini memprediksi perubahan kasus baru positif Covid-19 per satu juta penduduk (*new cases per million Covid-19*) di Indonesia menggunakan pembelajaran mesin. Pemodelan perubahan *new cases per million* diperlukan karena penyakit ini merupakan penyakit baru, sehingga sampai saat ini belum ada pemodelan deret waktu yang cukup akurat untuk menggambarkan kasus tersebut. Teknik *machine learning* yang akan digunakan adalah *Multi-Layer Perceptron* (MLP) dan *Support Vector Machine* (SVM) dan dibandingkan kinerja dari kedua teknik tersebut. Dari hasil perhitungan kinerja, prediksi *new cases per million Covid-19* yang dilakukan dengan menggunakan SVM (RMSE = 9,053) memiliki kinerja yang lebih baik dibandingkan dengan menggunakan MLP (RMSE = 10,284). Nilai RMSE yang lebih kecil menunjukkan kinerja yang lebih baik.

Kata kunci— *New cases per million*, Covid-19, MLP, SVM, RMSE

I. PENDAHULUAN

Akhir-akhir ini model *machine learning* menjadi model yang banyak digunakan dalam bidang peramalan (*forecasting*), di mana sebelumnya banyak menggunakan model statistik klasik. Penelitian dimulai pada tahun delapan puluhan dengan pengembangan model jaringan syaraf tiruan (*artificial neural networks*). Selanjutnya, penelitian memperluas konsep ke model lain, seperti *support vector machine*, pohon keputusan, dan lainnya, yang semuanya disebut model pembelajaran mesin [1]. Selain pengembangan dan analisis model, harus ada upaya untuk memvalidasi secara empiris berbagai model yang

ada dan membandingkan kinerjanya. Hal ini akan berguna bagi para praktisi, karena akan diberikan panduan untuk memilih model yang sesuai untuk menyelesaikan masalah dalam dunia nyata, sekaligus mengetahui kelebihan dan kekurangan masing-masing model.

Sebuah *time series* adalah sebuah rangkaian pengukuran historis y_t dari variabel yang dapat diamati y pada interval waktu tertentu. Rangkaian waktu dipelajari untuk beberapa tujuan seperti peramalan masa depan berdasarkan pengetahuan masa lalu, pemahaman fenomena yang mendasari langkah-langkah tersebut, atau hanya deskripsi singkat tentang fitur yang menonjol dari seri tersebut. Salah satu tujuan dari mempelajari rangkaian waktu adalah untuk melakukan peramalan. Peramalan nilai-nilai masa depan dari serangkaian waktu yang diamati memainkan peran penting dalam hampir semua bidang sains dan teknik, seperti kesehatan, ekonomi, keuangan, intelijen bisnis, meteorologi dan telekomunikasi [2].

Domain peramalan telah lama dipengaruhi oleh metode statistik linier seperti model ARIMA. Namun, pada akhir 1970-an dan awal 1980-an, menjadi semakin jelas bahwa model linier ternyata kurang sesuai untuk berbagai aplikasi nyata. Pada periode yang sama, beberapa model deret waktu non linier yang berguna diusulkan seperti model *bilinier*, ambang batas model *autoregresif* dan model *autoregressive conditional heteroscedasticity* (ARCH). Namun, studi analitik analisis deret waktu nonlinier dan peramalan masih dalam masa pertumbuhan dibandingkan dengan deret waktu linier [3]. Dalam dua dekade terakhir, model pembelajaran mesin telah menarik perhatian menjadi teknik yang banyak digunakan oleh peneliti di samping model statistik klasik dalam untuk tujuan peramalan. Model pembelajaran mesin adalah model yang digerakkan oleh data. Model *machine learning* adalah contoh model nonlinier yang hanya menggunakan data historis untuk mempelajari ketergantungan stokastik antara masa lalu dan masa depan.

Beberapa penelitian sebelumnya yang berkaitan dengan prediksi data *time series* telah banyak dilakukan oleh

peneliti. Penelitian [4] membahas metodologi untuk menerapkan regresi k-NN pada konteks peramalan *time series* yang dikembangkan. Tujuannya adalah untuk merancang alat otomatis, yaitu alat yang dapat bekerja tanpa campur tangan manusia. Penelitian [5] mengusulkan penggunaan *wavelet* dari fungsi-fungsi non linier dan model ARFIMA-ANN untuk peramalan harga listrik di masa depan. Model ini dirancang dengan tepat untuk menangkap pola harga daya yang paling kompleks, dan karenanya, mendapatkan akurasi perkiraan yang lebih baik. Tidak seperti kebanyakan model deret waktu, pendekatan yang diusulkan tidak sepenuhnya memaksakan kondisi stasioneritas dan linieritas yang ketat pada sekumpulan data. Penelitian [6] mengusulkan model dua tahap untuk memperkirakan seri waktu keuangan. Tahap pertama menggunakan metode pengelompokan untuk mengsegmentasi deret waktu ke dalam berbagai konteksnya. Tahap ke dua menggunakan *support vector regression* (SVR), satu untuk setiap konteks untuk memperkirakan nilai seri di masa mendatang. Data yang digunakan dalam eksperimen terdiri dari nilai-nilai dana ekuitas bank Brasil. Penelitian [7] mengusulkan kerangka kerja pemrosesan: jenis dan format sumber data, dan algoritme prakiraan berdasarkan pemrosesan bahasa alami. Studi ini menunjukkan bahwa model klasik menggunakan *collocations* kata mengungguli penggunaan *neural network*. Temuan ini dapat menghasilkan prakiraan yang lebih baik, yang mengarah pada penetapan harga penawaran yang lebih cerdas dan, akhirnya, peningkatan daya saing dalam bisnis perhotelan. Mereka juga dapat melayani kepentingan publik di bidang-bidang seperti manajemen parkir atau perencanaan transportasi umum. Penelitian [32] mengusulkan model peramalan baru yang disebut *first-order single-valued neutrosophic hesitant fuzzy time series* (SVNHFTS). Tujuannya adalah untuk meningkatkan model sebelumnya yaitu *neutrosophic time series* (NTS). Penelitian [9] bertujuan untuk meningkatkan efek prediksi deret waktu, dengan membuat studi sistematis berbagai metode prediksi deret waktu berdasarkan statistik dan pembelajaran mesin. Dalam percobaan, dibandingkan hasil prediksi beberapa metode prediksi. Secara khusus, banyak penelitian telah dilakukan pada pemilihan data eksperimental karena data *time series* yang representatif dapat lebih baik menguji efektivitas dan kepraktisan metode prediksi. Penelitian [10] mengusulkan sistem perdagangan energi periodik dalam *microgrid* berdasarkan ramalan energi dan konsumsi energi di masa depan. Dalam model yang diusulkan, perhitungan fungsi berdasarkan perkiraan perubahan energinya berdasarkan regresi proses *Gaussian* dan menentukan tindakan optimalnya. Penelitian ini membuktikan keberadaan harga perdagangan ekuilibrium dan membangun algoritma yang mengarah ke ekuilibrium [7].

Pandemi penyakit Covid-19 sudah menyebar hampir di seluruh negara di dunia termasuk Indonesia. Karena merupakan penyakit baru yang belum banyak diketahui karakteristiknya, pola perkembangan *new cases per million* kasus Covid-19 juga belum diketahui. *New cases*

per million adalah jumlah orang baru per hari yang positif menderita Covid-19 per satu juta penduduk. Perkembangan *new cases per million* Covid-19 adalah data *time series* [11], sehingga jumlah pada masa mendatang dapat diramalkan menggunakan data yang sudah ada. Banyak penelitian telah dilakukan terhadap perkembangan kasus Covid-19, baik dengan melakukan prediksi [12][13] ataupun *forecasting* [14]-[17]. Ada juga peneliti [38] yang menitikberatkan pada pemodelan [18]-[21]. Oleh karena itu pada penelitian ini dilakukan pemodelan perkembangan jumlah *new cases per million* Covid-19 di Indonesia dengan menggunakan *machine learning*, khususnya menggunakan teknik yang sesuai untuk data *time series*, yaitu menggunakan metode *Multi-Layer Perceptron* (MLP) dan *Support Vector Machine* (SVM)[22]. Tujuan penelitian ini adalah membandingkan teknik MLP dan teknik SVM untuk digunakan memprediksi *new cases per million* Covid-19 di Indonesia, sehingga mendapatkan model yang baik untuk menggambarkan perkembangan *new cases per million* Covid-19 di Indonesia.

II. METODE PENELITIAN

Metodologi dari metoda yang diusulkan secara garis besar digambarkan seperti yang tersaji pada Gambar 1. Secara umum metodologi ini dibagi menjadi dua tahapan besar, yaitu tahapan pra pelatihan dan tahapan evaluasi topologi. Tahapan pra pelatihan adalah tahapan yang dilakukan sebelum proses pembentukan model pada pembelajaran mesin yang meliputi: menentukan atau memilih dataset, prapemrosan data, dan menentukan teknik pembelajaran mesin yang digunakan. Tahapan evaluasi topologi dilakukan untuk mengetahui kinerja pembelajaran *neural networks* berdasarkan topologi yang sudah ditentukan maupun metode SVM. Tahapan ini meliputi: training, testing, dan perhitungan kinerja. Masing-masing tahapan dijelaskan pada subbab berikutnya.



Gambar. 1 Metode penelitian

A. Menyiapkan Dataset


Dataset yang digunakan dapat diambil dari <https://ourworldindata.org/coronavirus> khususnya untuk negara Indonesia. Data yang digunakan adalah data *new cases per million Covid-19*. Data kasus yang diambil adalah dari Maret 2020 sampai 28 Maret 2022.

B. Menentukan Teknik Pembelajaran Mesin

Teknik pembelajaran mesin yang digunakan adalah MLP dan SVM. *Multilayer perceptron* (MLP) adalah *artificial neural networks* [23] di mana setiap *neuron* pada *layer* terhubung penuh dengan setiap *neuron* pada *layer* berikutnya. MLP terdiri dari lapisan *input* untuk menerima sinyal, lapisan *output* yang membuat keputusan atau prediksi tentang *input*, dan di antara keduanya, sejumlah lapisan tersembunyi (*hidden layer*) yang merupakan mesin komputasi sebenarnya dari MLP. MLP dengan satu lapisan tersembunyi mampu mendekati setiap fungsi kontinu. MLP sering diterapkan pada masalah *supervised learning*: yaitu melatih pada serangkaian pasangan *input-output* dan belajar untuk memodelkan korelasi (atau dependensi) antara *input* dan *output* tersebut. Pelatihan melibatkan penyesuaian parameter, bobot, bias, dan tujuan dari model adalah untuk meminimalkan kesalahan. *Support Vector Machines* (SVM) adalah seperangkat metode pembelajaran terawasi yang digunakan untuk klasifikasi, regresi, dan deteksi *outlier*. Keuntungan dari SVM adalah: efektif dalam ruang dimensi tinggi, hemat memori. Kerugian dari SVM adalah tidak secara langsung memberikan perkiraan probabilitas [24].


Terdapat beberapa teknik dalam pembelajaran mesin yang dapat digunakan untuk melakukan regresi, misalnya: neural networks, Support Vector Machine (SVM), dan regresi linier. Dalam penelitian ini digunakan dua teknik yaitu neural network dan SVM. Neural network yang digunakan yaitu arsitektur multi-layer perceptron (MLP) dan bentuk khusus SVM yang digunakan untuk regresi, yaitu Support Vector Regression (SVR). Berikut ini dijelaskan tentang teknik MLP dan SVR tersebut.

MLP merupakan *feed forward neural network* yang mempunyai beberapa *neuron* yang berbobot. Semua *neuron* yang ada terhubung ke setiap *neuron* pada *layer* berikutnya. MLP minimal terdiri dari 3 *layer* yaitu *layer input*, satu *hidden layer*, dan *output layer*. Jadi MLP minimal mempunyai satu *hidden layer*. Neuron-neuron yang ada pada setiap *layer* ini tersusun dalam lapisan-lapisan yang terdiri dari satu *input layer*, satu atau lebih *hidden layer*, dan satu *output layer*. *Input layer* menerima sinyal dari luar, kemudian meneruskannya ke *hidden layer* pertama, yang akan berlanjut hingga mencapai *output layer*. Berikut ini adalah contoh neural network yang mempunyai bentuk arsitektur MLP yang mempunyai empat variabel *input*, dua *hidden layer* di mana masing-masing mempunyai 5 dan 3 *hidden neuron*, dan satu *output* seperti pada Gambar 2.



Gambar. 2 Contoh arsitektur MLP

Teknik SVR merupakan perluasan dari SVM yang biasa digunakan untuk tujuan klasifikasi. Jadi dapat dikatakan SVR adalah perluasan dari SVM yang digunakan untuk tujuan regresi. SVM biasanya digunakan untuk data berdimensi tinggi dengan menggunakan fungsi linier selama pembelajaran untuk menemukan *hyperplane* sebagai pemisah untuk klasifikasi. SVR sendiri menerapkan konsep meminimalkan risiko, dengan meminimalkan nilai ambang atas pada generalisasi *error* sehingga dapat menghindari terjadinya *overfitting*. Walaupun sama-sama digunakan untuk keperluan regresi, perbedaan SVR dan regresi linier dapat dilihat pada Gambar 3. Pada SVR, pengukuran regresi tidak menggunakan garis, melainkan menggunakan "tube", yang disebut dengan *Epsilon Insensitive Tube*. Tube ini merupakan *margin kesalahan (error)* yang masih diizinkan model. Kesalahan dihitung dengan menghitung jarak titik-titik yang berada di luar tube ke batas tube, sedangkan titik-titik yang berada di dalam tube errornya diabaikan seperti pada Gambar 3.



Gambar. 3 Ilustrasi SVR

C. Evaluasi Teknik yang Digunakan

Pelatihan dilakukan dengan jumlah data sebanyak 70% dari *dataset*, sedangkan pengujian dilakukan dengan jumlah data 30 % dari *dataset* [25]. Untuk perhitungan kinerja dari teknik yang digunakan, dihitung berdasarkan nilai *root mean of squared error* (RMSE) yang dihitung dengan Persamaan (1) [26]:

$$RMSE = \sqrt{\frac{1}{N} \sum_{t=1}^n (\hat{y}_t - y_t)^2} \quad (1)$$

dimana \hat{y}_t adalah nilai prediksi, y_t adalah nilai target. RMSE yang lebih rendah menunjukkan kinerja yang lebih tinggi.

III. HASIL DAN ANALISIS

Pada subbab ini dijelaskan pengolahan data mulai dari penyiapan data sampai dengan perhitungan dan perbandingan kinerja.

A. Dataset

Data yang digunakan adalah kasus positif baru per satu juta (*new_cases_per_million*) Covid-19 harian dan jumlah pengetesan, khususnya untuk negara Indonesia dari tanggal 2 Maret 2020 sampai 28 Maret 2022. Sebenarnya *dataset* tersebut mempunyai banyak atribut, namun pada penelitian ini hanya digunakan dua atribut, yaitu tanggal dan *new_cases_per_million* seperti ditampilkan pada Tabel I.


TABEL I
ATRIBUT DATA YANG DIGUNAKAN

No	Nama Atribut	Tipe Data
1	Tanggal	Date
2	<i>New_cases_per_million</i>	Real

Pada Tabel II adalah contoh potongan data dari tanggal 14 Maret 2022 sampai 28 Maret 2022.

TABEL III
ATRIBUT DATA YANG DIGUNAKAN

No	Tanggal	<i>New_cases_per_million</i>
1	03/14/22	29.226
2	03/15/22	146.974
3	03/16/22	161.115
4	03/17/22	132.077
5	03/18/22	124.54



Gambar. 4 Nilai *new cases per million* dan prediksi *new cases per million* dengan teknik MLP

Garis yang berwarna biru menunjukkan data asli *positive rate*, sedangkan garis hijau menunjukkan hasil prediksi *new cases per million* dengan menggunakan teknik pembelajaran mesin *multilayer perceptron* (MLP). Contoh data *new cases per million* dan prediksi *new cases per million* dengan menggunakan MLP dapat dilihat pada Tabel III. Contoh informasi detail pada Gambar 4 dapat dilihat pada Tabel III.

No	Tanggal	<i>New_cases_per_million</i>
6	03/19/22	89.477
7	03/20/22	134.82
8	03/21/22	89.98
9	03/22/22	109.089
10	03/23/22	95.295
11	03/24/22	58.293
12	03/25/22	53.915
13	03/26/22	52.135
14	03/27/22	34.477
15	03/28/22	23.071

B. Perbandingan Kinerja


Perbandingan kinerja dilakukan antara dua teknik pembelajaran mesin yang digunakan dalam prediksi yaitu menggunakan *neural network* dan *support vector machine* (SVM). Bentuk *neural network* yang digunakan adalah *multilayer perceptron* (MLP). MLP yang digunakan pada penelitian ini adalah mempunyai satu *hidden layer* dengan dua *neuron*, *cycles* = 200, *LR* = 0,01, *momentum* = 0,9, dan variasi bobotnya dilakukan secara *random*. Pelatihan dilakukan dengan jumlah data sebanyak 70 % dari dataset, sedangkan pengujian dilakukan dengan jumlah data 30% dari dataset. Pengukuran kinerja dilakukan dengan menghitung nilai RMSE untuk masing-masing teknik yang digunakan. Jadi atribut time series-nya adalah *new cases per million*. Dengan menggunakan *multi-layer perceptron* (MLP) didapatkan nilai RMSE adalah 10,284 dan grafiknya dapat dilihat pada Gambar 4 di bawah ini.

TABEL IIIII
NILAI *NEW CASES PER MILLION* DAN PREDIKSI *NEW CASES PER MILLION* MENGGUNAKAN MLP

Tanggal	<i>New cases per million</i>	Prediksi <i>new cases per million</i>
1/26/2022	29.226	25.755
2/9/2022	146.974	166.372

Tanggal	New cases per million	Prediksi new cases per million
2/12/2022	161.115	201.046
2/13/2022	132.077	156.070
2/20/2022	124.540	182.501
2/28/2022	89.477	113.690
3/2/2022	134.820	157.797
3/5/2022	89.980	131.233
3/7/2022	109.089	91.136
3/8/2022	95.295	122.347
3/10/2022	58.293	89.233
3/11/2022	53.915	69.946
3/14/2022	52.135	42.054
3/17/2022	34.477	47.108
3/22/2022	23.071	30.938

Teknik SVM yang digunakan adalah SVM yang khusus untuk regresi yang disebut SVR. Jumlah *cache kernel* yang digunakan pada penelitian ini adalah 200. Dengan menggunakan *support vector machine* (SVM) didapatkan nilai RMSE adalah 9,053, dan grafiknya dapat dilihat pada Gambar 5 di bawah ini:



Gambar. 5 Nilai *new cases per million* dan prediksi *new cases per million* dengan teknik SVM

Garis yang berwarna biru menunjukkan data asli **new cases per million**, sedangkan garis hijau menunjukkan hasil prediksi dengan menggunakan teknik pembelajaran mesin *support vector machine* (SVM). Contoh data prosen dan prediksi prosen dengan menggunakan SVM dapat dilihat pada Tabel IV. Contoh informasi detail pada Gambar 5 dapat dilihat pada Tabel IV.

TABEL IV
NILAI *NEW CASES PER MILLION* DAN PREDIKSI *NEW CASES PER MILLION* MENGGUNAKAN SVM

Tanggal	New cases per million	Prediksi new cases per million
1/26/2022	29.226	25.755
2/9/2022	146.974	166.372
2/12/2022	161.115	201.046
2/13/2022	132.077	156.070
2/20/2022	124.540	182.501
2/28/2022	89.477	113.690

Tanggal	New cases per million	Prediksi new cases per million
3/2/2022	134.820	157.797
3/5/2022	89.980	131.233
3/7/2022	109.089	91.136
3/8/2022	95.295	122.347
3/10/2022	58.293	89.233
3/11/2022	53.915	69.946
3/14/2022	52.135	42.054
3/17/2022	34.477	47.108
3/22/2022	23.071	30.938

Dengan membandingkan nilai RMSE yang diperoleh dengan teknik MLP maupun SVM, ternyata teknik SVM mempunyai nilai yang lebih kecil. Artinya teknik pembelajaran mesin menggunakan SVM mempunyai kinerja yang lebih baik dibandingkan teknik MLP untuk memprediksi *new cases per million* Covid-19 di Indonesia.

Dari kedua gambar di atas yaitu Gambar 4 dan Gambar 5, dapat dilihat bahwa kasus Covid-19 di Indonesia terjadi dalam 3 gelombang, di mana puncak gelombang pertama sekitar pertengahan Februari 2021, puncak gelombang ke dua sekitar pertengahan Juli 2022, dan puncak gelombang ke tiga terjadi sekitar pertengahan Februari 2022. Gelombang pertama terjadi ketika virus relatif belum bermutasi, pada gelombang ke dua peningkatan kasus karena adanya varian Delta, sedangkan pada gelombang ke tiga peningkatan kasus karena adanya varian *Omicron*.

IV. KESIMPULAN

Teknik pembelajaran *support vector machine* (SVM) mempunyai kinerja yang lebih baik dibandingkan dengan teknik *neural network* berbentuk MLP dalam memprediksi *new cases per million* Covid 19, khususnya untuk kasus di Indonesia. Dari data perkembangan jumlah kasus baru per satu juta penduduk, di Indonesia telah terjadi tiga gelombang perkembangan kasus dengan puncaknya di sekitar bulan Februari 2021, Juli 2021, dan Februari 2022. Setelah dilakukan prediksi diharapkan dilanjutkan dengan *forecasting* beberapa waktu ke depan sehingga dapat diketahui bentuk kurva *new cases per million* tersebut apakah sudah mulai melandai atau masih stabil, atau bahkan makin meningkat.

REFERENSI

- [1] T. Hastie, R. Tibshirani and J.H. Friedman, "The Elements of Statistical Learning: Data mining, Inference, and Prediction". Springer, New York: Springer, 2009.
- [2] C.C. Aggarwal, *Neural Networks and Deep Learning*. New York: Springer International Publishing, 2018.
- [3] Ahmed, K. Nesreen, Atiya, F. Amir, Gayar and Hisham, "Empirical Comparison of Machine Learning Models for Time Series Forecasting", *Econometric Reviews*, Vol. 29, No. 5, PP. 594-621, 2010.
- [4] F. Martinez, M.P. Frias and M.D. Pérez, "A Methodology for Applying kNearest Neighbor to Time Series Forecasting", *Artificial Intelligence Review*, Vol. 52, PP. 2019-2037, 2019. <https://doi.org/10.1007/s10462-017-9593-z1>
- [5] F. Saâdaoui and H. Rabbouch, "A Wavelet-Based Hybrid Neural Network for Short-Term Electricity Prices Forecasting", *Artificial Intelligence Review*, Vol. 52, PP. 649-669, 2019. <https://doi.org/10.1007/s10462-019-09702-x>

- [6] L.F.S. Vilela, R.C. Leme and C.A.M., "Forecasting financial series using clustering methods and support vector regression", *Artificial Intelligence Review*, Vol. 52, PP. 743–773, 2019, <https://doi.org/10.1007/s10462-018-9663-x>
- [7] M. Kamola and P. Arabas, "Improving Time-Series Demand Modeling in Hospitality Business by Analytics of Public Event Datasets", *IEEE Access*, Vol. 8, PP. 53666–53677, 2020.
- [8] B. Tanuwijaya, G. Selvachandran and L.H. Son, "A Novel Single Valued Neutrosophic Hesitant Fuzzy Time Series Model: Applications to Indonesian and Argentinian Stock Index Forecasting", *IEEE Access*, Vol. 8, PP. 60126–60141, 2020.
- [9] Y. Yang and Y. Yang, "Hybrid Method for Short-Term Time Series Forecasting Based on EEMD", *IEEE Access*, Vol. 8, PP. 1715–61928, 2020.
- [10] G. Jeong, S. Park and G. Hwang, "Time Series Forecasting Based Day-Ahead Energy Trading in Microgrids: Mathematical Analysis and Simulation", *IEEE Access*, Vol. 8, PP. 63885–63900, 2020.
- [11] S.A. Rizvi, M. Umair and M.A. Cheema, "Clustering of Countries for COVID-19 Cases based on Disease Prevalence", *Health Systems and Environmental Indicators*, 2021, <https://doi.org/10.1101/2021.02.15.21251762>
- [12] Y. Zhu et al., "Fix Contrast for COVID-19 Mild-to-Critical Prediction", *IEEE TRANSACTIONS ON BIOMEDICAL ENGINEERING*, vol. 68, no. 12, pp. 3725–3736, 2021.
- [13] V. K. Gupta, A. Gupta, D. Kumar, and A. Sardana, "Prediction of COVID-19 Confirmed, Death, and Cured Cases in India Using Random Forest Model", *BIG DATA MINING AND ANALYTICS*, vol. 4, no. 2, pp. 116–123, 2021, doi: 10.26599/BDMA.2020.9020016.
- [14] M. Shawaqfeh and F. Almomani, "Results in Physics Forecast of the outbreak of COVID-19 using artificial neural network: Case", *Results Phys.*, vol. 27, no. June, p. 104484, 2021, doi: 10.1016/j.rinp.2021.104484.
- [15] M. Marzouk, N. Elshaboury, A. Abdel-latif, and S. Azab, "Deep learning model for forecasting COVID-19 outbreak in Egypt", *Process Saf. Environ. Prot.*, vol. 153, no. March 2020, pp. 363–375, 2021, doi: 10.1016/j.psep.2021.07.034.
- [16] M. Wiecek, J. Silka, and M. Wozniak, "Science and C. Phenomena, " Neural network powered COVID-19 spread forecasting model," *Chaos, Solitons and Fractals*, vol. 140, 2020, <https://doi.org/10.1016/j.chaos.2020.110203>.
- [17] H. Friji, R. Hamadi, H. Ghazzai, S. Member, H. Besbes, and Y. Massoud, "A Generalized Mechanistic Model for Assessing and Forecasting the Spread of the COVID-19 Pandemic," *IEEE Access*, vol. 9, 2021, doi: 10.1109/ACCESS.2021.3051929
- [18] A. Alarjani, T. Nasseef, S. M. Kamal, B. V. S. Rao, M. Mahmud, and S. Uddin, "Application of Mathematical Modeling in Prediction of COVID-19 Transmission Dynamics," *Arab. J. Sci.*, vol. 9, 2022, doi: 10.1007/s13369-021-06419-4.
- [19] F. Rustam, A. A. Reshi, and A. Mehmood, "COVID-19 Future Forecasting Using Supervised Machine Learning Models," *IEEE Access*, vol. 8, pp. 101489–101499, 2020, doi: 10.1109/ACCESS.2020.2997311.
- [20] R. Lotfi, K. Kheiri, A. Sadeghi, and E. Babaei, "An extended robust mathematical model to project the course of COVID-19 epidemic in Iran," *Ann. Oper. Res.*, 2022, doi: 10.1007/s10479-021-04490-6.
- [21] A. L. I. Arjomandi-nezhad and A. Ahmadi, "Pandemic-Aware Day-Ahead Demand Forecasting Using Ensemble Learning," *IEEE Access*, vol. 10, pp. 7098–7106, 2022, doi: 10.1109/ACCESS.2022.3142351.
- [22] F. Handayani, et al., "Komparasi Support Vector Machine, Logistic Regression Dan Artificial Neural Network dalam Prediksi Penyakit Jantung," *Jurnal Edukasi dan Penelitian Informatika*, vol. 7, no. 3, pp. 2891–2904, 2021.
- [23] S. Agrebi and A. Larbi, "Use of artificial intelligence in infectious diseases", *Artificial Intelligence in Precision Health*, PP. 415–438, 2020.
- [24] G. Shmueli, P.C. Bruce, I. Yahav and N.R. Patel, "Data Mining for Business Analytics: Concepts, Techniques, and Applications", 27, Jersey: John Wiley & Sons, 2020.
- [25] Q.H. Nguyen, H.B. Ly, L.S. and N. Al-Ansari, "Influence of Data Splitting on Performance of Machine Learning Models in Prediction of Shear Strength of Soil", *Mathematical Problems in Engineering*, 2021, <https://doi.org/10.1155/2021/4832864>
- [26] S. Namasudra, S. Dhamodharavadhani and R. Rathipriya, "Nonlinear Neural Network Based Forecasting Model for Predicting COVID-19 Cases", *Neural Processing Letters*, 2021, <https://doi.org/10.1007/s11063-021-10495-w4>.

18%

SIMILARITY INDEX

PRIMARY SOURCES

1	jurnal.ubl.ac.id Internet	50 words — 1%
2	unisbank.ac.id Internet	32 words — 1%
3	docplayer.info Internet	31 words — 1%
4	repo.undiksha.ac.id Internet	29 words — 1%
5	www.ijraset.com Internet	29 words — 1%
6	computingonline.net Internet	28 words — 1%
7	123dok.com Internet	22 words — 1%
8	ejurnal.seminar-id.com Internet	20 words — 1%
9	etd.astu.edu.et Internet	20 words — 1%
10	id.scribd.com Internet	

19 words — < 1%

11 nsuworks.nova.edu
Internet

19 words — < 1%

12 dblp.dagstuhl.de
Internet

17 words — < 1%

13 wgbis.ces.iisc.ernet.in
Internet

17 words — < 1%

14 repository.upiypk.ac.id
Internet

16 words — < 1%

15 kirj.ee
Internet

15 words — < 1%

16 github.com
Internet

14 words — < 1%

17 ijcopi.org
Internet

14 words — < 1%

18 ijisae.org
Internet

14 words — < 1%

19 cemse.kaust.edu.sa
Internet

13 words — < 1%

20 manglar.uninorte.edu.co
Internet

13 words — < 1%

21 www.scribd.com
Internet

13 words — < 1%

22 doku.pub

12 words — < 1%

23 openaccess.altinbas.edu.tr

Internet

12 words — < 1%

24 rcastoragev2.blob.core.windows.net

Internet

12 words — < 1%

25 vaskoedo.wordpress.com

Internet

12 words — < 1%

26 Submitted to Telkom University

Your Indexed Documents

11 words — < 1%

27 ikee.lib.auth.gr

Internet

11 words — < 1%

28 repository.uksw.edu

Internet

11 words — < 1%

29 www.iiitdm.ac.in

Internet

11 words — < 1%

30 mehdijournal.com

Internet

10 words — < 1%

31 repository.ub.ac.id

Internet

10 words — < 1%

32 researchprofiles.canberra.edu.au

Internet

10 words — < 1%

33 www.ia.pw.edu.pl

Internet

10 words — < 1%

34 apc.aast.edu

9 words — < 1%

35 journal-isi.org

Internet

9 words — < 1%

36 jtsiskom.undip.ac.id

Internet

9 words — < 1%

37 repository.its.ac.id

Internet

9 words — < 1%

38 repository.unair.ac.id

Internet

9 words — < 1%

39 scik.org

Internet

9 words — < 1%

40 www.arxiv-vanity.com

Internet

9 words — < 1%

41 www.slideshare.net

Internet

9 words — < 1%

42 digilib.unila.ac.id

Internet

8 words — < 1%

43 revistas.ucc.edu.co

Internet

8 words — < 1%

44 techscience.com

Internet

8 words — < 1%

45 www.preprints.org

Internet

8 words — < 1%

46 www.wjgnet.com

Internet

8 words — < 1%

47

zombiedoc.com

Internet

8 words — < 1%

48

sciendo.com

Internet

7 words — < 1%

49

jurnal.murnisadar.ac.id

Internet

6 words — < 1%

EXCLUDE QUOTES ON

EXCLUDE BIBLIOGRAPHY ON

EXCLUDE SOURCES OFF

EXCLUDE MATCHES OFF