

KLASIFIKASI PENELITIAN DALAM DEEP LEARNING

Muh. Ibnu Choldun R.^{1,3}, Kridanto Surendro²

^{1,2} Sekolah Tinggi Elektro dan Informatika, Institut Teknologi Bandung (ITB)

³ Jurusan Manajemen Informatika Politeknik Pos Indonesia

¹ibnuholdun@students.itb.ac.id, ³ibnuholdun@poltekpos.ac.id

²endo@stei.itb.ac.id

Abstrak

Deep learning adalah aspek jaringan saraf tiruan (*artificial neural network*) yang bertujuan untuk meniru metode pembelajaran mesin (*machine learning*) yang digunakan manusia untuk mendapatkan jenis pengetahuan tertentu. Deep learning dapat diartikan sebagai teknik yang menggunakan jaringan saraf yang memanfaatkan banyak hidden layer antara layer input dan output. Hal ini berbeda dengan jaringan saraf biasa hanya menggunakan satu hidden layer. Walaupun telah mengalami kesuksesan di berbagai bidang, misalnya: klasifikasi pola, pengenalan ucapan, peringkasan dokumen, dan lain-lain, namun belum ada penjelasan teoritis yang mumpuni mengapa deep learning bisa memberikan kinerja yang baik. Untuk lebih memahami bagaimana cara kerja deep learning telah banyak dilakukan penelitian yang dilakukan yang secara garis besar dapat diklasifikasikan sebagai penelitian pustaka, optimisasi, dan penelitian aplikatif. Karena banyak area dalam deep learning yang belum menjelaskan secara teoritis, peluang untuk melakukan penelitian di bidang deep learning masih terbuka lebar.

Kata kunci— machine learning, neural network, deep learning, kinerja, klasifikasi penelitian

1 Pendahuluan

Dengan semakin meluasnya penggunaan sensor dan Internet of Thing (IoT), semakin meningkat pula kebutuhan untuk menangani data-data yang mempunyai karakteristik: volume tinggi, kecepatan tinggi, dan variasi tinggi. Berbagai negara telah mengembangkan peta jalan strategis untuk mentransformasikan perusahaan untuk mengambil keuntungan dari kemunculan infrastruktur yang ditandai munculnya Internet of Things dan data science. Sebagai contoh, Jerman memperkenalkan kerangka kerja industri 4.0 pada tahun 2010, yang kemudian berkembang menjadi kolaborasi antar negara-negara Eropa.[1]

Data driven intelligence telah menarik upaya penelitian yang luas, misalnya penggunaan machine learning untuk mengolah data tersebut. Teknologi machine learning banyak digunakan dalam berbagai aspek, mulai dari pencarian web sampai penyaringan isi pada jaringan sosial untuk memberi rekomendasi misalnya pada situs e-commerce. Penggunaan teknologi ini semakin berkembang sejak munculnya produk-produk di pasaran misalnya seperti smartphone. Machine learning digunakan untuk mengidentifikasi objek gambar, transkripsi dari ucapan ke teks, mencocokkan item berita, memproduksi barang sesuai selera konsumen, dan memilih hasil pencarian yang relevan.[1]

Teknik machine learning konvensional mempunyai keterbatasan pada kemampuan memproses data alamiah yang masih mentah. Selama beberapa dekade, mengkonstruksi sebuah machine

learning atau pengenalan pola membutuhkan teknik-teknik yang teliti dan domain keahlian yang mencukupi untuk merancang sebuah fitur ekstraktor yang mengubah data mentah ke dalam representasi internal yang sesuai. [2]

Representation learning adalah sekumpulan metoda yang memungkinkan sebuah mesin untuk menerima masukan berupa data mentah dan secara otomatis menemukan representasi yang diperlukan untuk deteksi atau klasifikasi. Deep learning adalah metoda representation learning dengan tingkat representasi yang majemuk, yang diperoleh dengan menyusun modul yang sederhana tetapi non linier yang masing-masing mentransformasikan dari level sederhana ke tingkat yang lebih tinggi, yaitu tingkat yang lebih abstrak. Dengan komposisi tersebut, fungsi-fungsi yang sangat kompleks dapat dipelajari. [2]

2 Machine Learning dan Deep Learning

Di bawah ini akan dijelaskan tentang machine learning dan deep learning, serta perbandingan di antara keduanya.

2.1 Machine Learning


Machine learning adalah sebuah tipe kecerdasan buatan yang menyediakan komputer dengan kemampuan untuk belajar dari data, tanpa secara eksplisit harus mengikuti instruksi yang terprogram. Beberapa metoda machine learning adalah supervised learning, unsupervised learning, dan

reinforcement learning. Supervised learning bertugas untuk mempelajari mapping dari input ke target atau output. Unsupervised learning bertugas menemukan pola atau fitur dalam input data, dan tergantung pada target/output. Reinforcement learning adalah pembelajaran terhadap apa yang dilakukan untuk memaksimalkan reward.

Beberapa contoh dari algoritma machine learning adalah: Naive Bayes, K-Means, K-nearest-neighbor, dan ID3. Algoritma machine learning yang sedang populer saat ini adalah menggunakan jaringan syaraf tiruan. [3],[4]


2.2 Jaringan Syaraf Tiruan (Artificial Neural Network)

Neural network adalah model yang terinspirasi oleh bagaimana neuron dalam otak manusia bekerja. Tiap neuron pada otak manusia saling berhubungan dan informasi mengalir dari setiap neuron tersebut. Gambar di bawah adalah ilustrasi neuron dengan model matematisnya.



Gambar 1 Neuron dengan model matematis

Arsitektur umum dari neural network adalah sebagai berikut:




Gambar 2 Arsitektur umum neural network

Arsitektur diatas biasa disebut sebagai Multi Layer Perceptron (MLP) atau Fully-Connected Layer. Arsitektur pertama mempunyai 3 buah neuron pada Input Layer dan 2 buah node Output Layer. Diantara Input dan Output, terdapat 1 Hidden Layer dengan 4 buah neuron. Deep Neural Network (DNN) adalah artificial neural network yang memiliki banyak layer. Pada umumnya, deep neural network memiliki lebih dari 3 layers (input layer, N hidden layers, output layer), dengan kata lain adalah MLP dengan lebih banyak layer. Karena ada relatif banyak layer, disebutlah deep. Proses pembelajaran pada DNN disebut sebagai deep learning. Jaringan neural network pada DNN disebut deep network.[3],[4]

2.2.1 Gradient Descent


Gradient Descent adalah algoritma untuk mengoptimalkan iteratif yang digunakan pada Machine Learning untuk menemukan hasil yang terbaik (minima kurva). Algoritma iteratif berarti bahwa kita perlu mendapatkan hasilnya berkali-kali untuk mendapatkan hasil yang paling optimal atau bisa dikatakan hampir sempurna. Kualitas iteratif dari Gradient Descent membantu grafik yang tidak dilengkapi untuk membuat grafik sesuai dengan optimal pada data.[3],[4]



Gambar 4 Grafik error

2.2.2 Epoch

Epoch adalah ketika seluruh dataset sudah melalui proses training pada Neural Network sampai dikembalikan ke awal untuk sekali putaran, karena satu Epoch terlalu besar untuk dimasukkan (feeding) kedalam komputer maka dari itu per dibagi kedalam satuan kecil (batches). Namun perlu diingat bahwa dataset yang digunakan terbatas dan untuk mengoptimalkan pembelajaran, metoda digunakan adalah Gradient Descent yang merupakan proses iteratif. Jadi, mengupdate weight (bobot) dengan satu epoch saja tidak cukup. Seiring bertambahnya jumlah epoch, semakin banyak pula weight (bobot) yang berubah dalam Neural Network dan kurvanya melengkung dari kurva yang kurang sesuai hingga selaras dengan kurva yang overfitting.[3],[4]



Gambar 3 Kurva overfitting, optimum dan underfitting

Batch Size

Batch Size adalah jumlah sampel data yang disebarkan ke Neural Network. Contoh: dipunyai 100 dataset dan batch size adalah 5 maka algoritma ini akan menggunakan 5 sampel data pertama dari 100 data (ke1, ke2, ke3, ke4, dan ke5) lalu disebarkan atau ditraining oleh Neural Network sampai selesai

kemudian mengambil kembali 5 sampel data kedua dari 100 data (ke6, ke7, ke8, ke9, dan ke10), dan begitu seterusnya sampai 5 sampel data ke 20 ($100/5=20$). [3],[4]

2.3 Deep Learning

Deep learning adalah salah satu cabang machine learning yang menggunakan Deep Neural Network untuk menyelesaikan permasalahan pada domain machine learning. Deep neural network adalah neural network yang mempunyai jumlah hidden layer lebih dari satu. Salah satu tantangan dalam keberhasilan implementasi deep learning dalam adalah pengaturan nilai untuk berbagai hiperparameter, salah satunya adalah topologi jaringannya, yang sangat berkaitan erat dengan jumlah hidden layer dan jumlah hidden neuron. Penentuan jumlah hidden layer dan jumlah neuron sangat penting dan memiliki pengaruh besar pada kinerja deep learning.


2.4 Perbandingan antara pembelajaran mendalam dan pembelajaran mesin tradisional

Deep learning dan machine learning tradisional adalah teknik kecerdasan buatan untuk memodelkan hubungan kompleks antara input dan output seperti yang ditunjukkan pada Gambar 4. Selain struktur hirarkis yang tinggi, deep learning juga memiliki atribut khas dibandingkan pembelajaran mesin tradisional dalam hal fitur pembelajaran, konstruksi model, dan pelatihan model.

Deep learning mengintegrasikan pembelajaran fitur dan konstruksi model dalam satu model. Arsitektur deep neural networks dengan banyak lapisan tersembunyi pada dasarnya adalah operasi multi-level nonlinier, yang mentransfer representasi setiap layer (atau fitur) dari input asli ke representasi yang lebih abstrak di lapisan yang lebih tinggi untuk menemukan struktur inheren yang rumit. Misalnya, fitur-fitur seperti bagian tepi, sudut, kontur, dan objek, diabstraksi lapis demi lapis dari suatu gambar. Representasi fitur abstrak ini kemudian dimasukkan ke lapisan klasifikasi untuk melakukan tugas klasifikasi atau regresi. Secara keseluruhan, deep learning adalah struktur pembelajaran end-to-end dengan keterlibatan inferensi manusia yang minimum, dan parameter-parameter pembelajaran akan dilatih bersama.

Sebaliknya, pembelajaran mesin tradisional melakukan ekstraksi fitur dan konstruksi model secara terpisah, dan setiap modul dibangun selangkah demi selangkah. Fitur *handcrafted* diekstraksi dengan mengubah data mentah menjadi domain yang berbeda (misalnya, statistik) untuk mengambil informasi representatif yang membutuhkan pengetahuan domain ahli. Selanjutnya, seleksi fitur dilakukan untuk

meningkatkan relevansi dan mengurangi redundansi di antara fitur sebelum memasukkan ke dalam model. Teknik machine tradisional biasanya memiliki struktur dangkal dengan paling banyak tiga layer (misalnya input, output, dan satu hidden layer). Dengan demikian, kinerja model yang dibangun tidak hanya bergantung pada optimalisasi algoritma yang diadopsi tetapi juga sangat dipengaruhi oleh fitur handcrafted. Umumnya, ekstraksi fitur dan seleksi memakan waktu, dan sangat bergantung pada pengetahuan domain.



Gambar 4 Ilustrasi perbandingan machine learning dan deep learning

2.5 Arsitektur Deep Learning

Adapun beberapa arsitektur dari deep learning adalah seperti penjelasan di bawah ini. [2],[3],[4]

2.5.1 Convolutional Neural Network

Convolutional Neural Network (CNN/ConvNet) adalah salah satu algoritma dari deep learning yang merupakan pengembangan dari Multilayer Perceptron (MLP). CNN digunakan untuk mengklasifikasi data yang terlabel dengan menggunakan metode supervised learning, yang mana cara kerja dari supervised learning adalah terdapat data yang dilatih dan terdapat variabel yang ditargetkan sehingga tujuan dari metode ini adalah mengelompokkan suatu data. CNN sering digunakan untuk mengenali benda atau pemandangan, dan melakukan deteksi dan segmentasi objek. CNN belajar langsung dari data citra, sehingga menghilangkan ekstraksi ciri secara manual. Lapisan-lapisan CNN memiliki susunan neuron 3 dimensi (lebar, tinggi, kedalaman). Lebar dan tinggi merupakan ukuran lapisan sedangkan kedalaman mengacu pada jumlah lapisan. Sebuah CNN dapat memiliki puluhan hingga ratusan lapisan yang masing-masing belajar mendeteksi berbagai gambar. Pengolahan citra diterapkan pada setiap citra latih pada resolusi yang berbeda, dan output dari masing-masing gambar yang diolah dan digunakan sebagai input ke lapisan berikutnya. Pengolahan citra dapat dimulai sebagai fitur yang sangat sederhana, seperti kecerahan dan tepi atau meningkatkan kompleksitas pada fitur


yang secara unik menentukan objek sesuai ketebalan lapisan.[2],[3],[4]



Gambar 5 Convolutional Neural Network

2.3.2 Recurrent Neural Network


Ide dasar recurrent neural network (RNN) adalah membuat topologi jaringan yang mampu merepresentasikan data sequential (sekuensial) atau time series, misalkan data ramalan cuaca. Cuaca hari ini bergantung kurang lebih pada cuaca hari sebelumnya. Sebagai contoh apabila hari sebelumnya mendung, ada kemungkinan hari ini hujan. Walau ada yang menganggap sifat data sekuensial dan time series berbeda, RNN berfokus sifat data dimana instans waktu sebelumnya ($t-1$) mempengaruhi instans pada waktu berikutnya (t). Intinya, mampu mengingat history. Secara lebih umum, diberikan sebuah sekuens data $x = (x_1, \dots, x_N)$. Data x_t (misal vektor, gambar, teks, suara) dipengaruhi oleh data sebelum-sebelumnya (history), ditulis sebagai $P(x_t | \{x_1, \dots, x_{t-1}\})$. [2],[3],[4]



Gambar 6 Recurrent Neural Network

2.3.3 Recursive neural network


Recursive neural network memiliki struktur rekursif. Topologi recursive neural network berbeda dengan recurrent neural network. Pada recurrent neural network bentuk topologinya melambungkan sequence, sedangkan pada recursive neural network melambungkan compositionality. Struktur pada recursive neural network melambungkan hirarki. Data yang memenuhi sifat compositionality berarti memiliki strukturhirarkis. Struktur hirarkis ini menggambarkan bagaimana unit-unit lebih kecil berinteraksi sebagai satu kesatuan. Artinya, interpretasi/pemaknaan unit yang lebih besar dipengaruhi oleh interpretasi/pemaknaan unit lebih kecil (subunit).[4]



Gambar 7 Recursive neural network


2.3.4 Deep Autoencoder

Autoencoder adalah model neural network yang memiliki input dan output yang sama. Autoencoder mempelajari data input dan berusaha untuk melakukan rekonstruksi terhadap data input tersebut. Autoencoder biasa digunakan untuk mengurangi dimensi dari features (Dimensionality Reduction). Jika kita mempunyai data yang mempunyai dimensi yang sangat tinggi (data dengan jumlah features yang sangat banyak) bisa jadi tiap features yang ada tersebar pada setiap dimensi dari data sehingga setiap data yang ada terlihat sangat berbeda. Untuk mengatasi masalah tersebut kita membutuhkan data yang sangat banyak atau mengurangi dimensi data tersebut.



Gambar 8 Deep Autoencoder

Autoencoder terdiri dari dua bagian utama yaitu encoder dan decoder. Diantara encoder dan decoder, terdapat code layer. Jumlah neuron pada code layer adalah jumlah dimensi yang diharapkan untuk dapat mengurangi dimensi data.[1],[3],[4]



Gambar 9 Encoder dan decoder

3 Penelitian Deep Learning

Penelitian *deep learning* berkembang pesat beberapa tahun terakhir karena kemampuannya untuk mempelajari representasi data yang kemudian digunakan untuk deteksi atau klasifikasi. Secara garis besar penelitian tersebut dapat dikelompokkan dalam penelitian: kajian teori/penelitian pustaka, optimisasi, dan penelitian aplikatif.

3.1 Penelitian Pustaka

Para peneliti di bidang neural network telah memusatkan perhatian pada model neural network yang disusun oleh beberapa hidden layer. Misalnya, berdasarkan hasil eksperimen dan pertimbangan heuristik struktur yang lebih dalam (jumlah hidden layer lebih banyak) *deep learning* memberikan kinerja yang lebih baik. Walaupun hasil eksperimen menunjukkan demikian, teori-teori yang mendukung hasil ini tersedia secara mapan. Beberapa peneliti melakukan penelitian pustaka dengan membandingkan hasil penelitian yang satu dengan yang lainnya, contohnya adalah sebagai berikut:

Tabel 1 Contoh penelitian pustaka

No	Pengarang	Deskripsi
1	[5]	Membandingkan <i>deep structure</i> dengan <i>shallow structure</i>
2	[6]	Mereview 210 paper <i>deep learning</i> di bidang <i>computer vision</i> dengan memfokuskan pada kontribusi dan tantangan paper
3	[7]	Menjelaskan <i>deep learning</i> menunjukkan kinerja yang baik dalam analisis gambar, pengenalan suara, dan pemrosesan bahasa alami, namun tidak disertai penjelasan teori yang cukup.

Beberapa penelitian lain yang berupa penelitian pustaka adalah [8],[9],[10],[11]

3.2 Optimisasi

Deep learning bekerja melalui proses optimisasi. Dengan kata lain, *artificial neural networks* belajar dari data dengan cara mengoptimalkan fungsi objektif. Dari pertengahan tahun 80-an hingga sekarang, teknik optimisasi yang digunakan berbasis *first-order gradient* dari fungsi objektif yang disebut sebagai *gradient descent*. Dipadukan dengan *chain rule*, *gradient descent* pada neural networks dikenal dengan algoritma *back-propagation*.

Di ranah *mathematical optimization*, *gradient descent* merupakan metode yang paling sederhana dan telah banyak tersedia metode-metode optimisasi lain yang lebih canggih. Alasan masih digunakannya adalah skalabilitas komputasi: *gradient descent* memiliki kompleksitas linear terhadap pertambahan data dan juga mudah untuk dikomputasi secara paralel (dengan memanfaatkan GPU). Karakteristik ini memungkinkan sebuah model *neural network* yang cukup besar untuk dilatih dengan jutaan data latih. Salah tujuan dari pembelajaran adalah meminimalkan error sehingga kinerja dari *deep learning* diukur oleh square error. Ada beberapa cara untuk meminimalkan square error salah satunya melalui *gradient descent*. [8] Beberapa cara untuk meminimalkan error antara lain adalah:

1. mengoptimalkan jumlah hidden layer dan jumlah neuron
2. menghapus neuron dari jaringan (*dropout*)

Beberapa penelitian terkait dengan pengoptimalan jumlah hidden layer dengan dan/atau jumlah neuron tersaji dalam tabel di bawah ini.

Tabel 2 Contoh penelitian menghitung jumlah layer dan neuron

No	Pengarang	Metoda
1	[12]	Mencoba dengan 151 fungsi konvergen
2	[13]	Menggunakan algoritma Particle Swarm Optimization
3	[14]	Trial and error

Beberapa penelitian lain yang berkaitan dengan penghitungan jumlah hidden layer dan jumlah neuron adalah [30],[31],[32],[33],[34]. Sampai saat ini, menentukan jumlah hidden layer dan jumlah neuron yang optimal masih menyisakan permasalahan dalam neural network, karena belum mempunyai panduan yang pasti.

Contoh penelitian yang membahas tentang *dropout* misalnya adalah:

Tabel 3 Contoh penelitian dropout

No	Pengarang	Deskripsi
1	[15]	Untuk mengatasi overfitting
2	[16]	Dropout untuk mengurangi noise

3.3 Penelitian Aplikatif

Deep learning telah menunjukkan kinerja yang mengagumkan dalam bidang klasifikasi citra, pengenalan ucapan, aktivitas bisnis, dll. Di bawah ini disajikan beberapa contoh penelitian aplikatif tersebut.

3.3.1 Klasifikasi Citra

Sampai saat ini permasalahan klasifikasi citra diselesaikan dengan menggunakan pendekatan pembelajaran mesin (*machine learning*) di mana peningkatan kualitas klasifikasi dapat dilakukan dengan cara menambah jumlah *training dataset*, menggunakan model yang lebih efisien dan menggunakan teknik-teknik untuk mencegah *overfitting*. Ketiga cara tersebut saling berhubungan sama lain karena ketika jumlah *training dataset* dibuat menjadi lebih besar maka model yang digunakan juga harus memiliki kapasitas yang besar dan teknik pencegahan *overfitting* yang digunakan juga perlu disesuaikan dengan kapasitas data yang dipelajari. Untuk mengatasi masalah tersebut, digunakan *Deep Convolutional Neural Network (DCNN)* yang menggunakan delapan buah layers yang terdiri dari *Rectified Linear Units (ReLU)*s dan teknik *dropout*, telah mampu memecahkan rekor klasifikasi citra terhadap *dataset ImageNet Large-Scale Visual Recognition Challenge (ILSVRC)* 2010 (1,2 juta citra resolusi tinggi dari 1000 kelas) dengan kesalahan rata-rata 37,5% (top-1) dan 17% (top-5).[17]. Beberapa penelitian terkait klasifikasi gambar adalah[38],[39],[40],[41].

3.3.2 Pengenalan Ucapan

Hidden Markov Models yang dikombinasikan dengan Gaussian Mixture Models (HMM-GMM) adalah model yang sangat sukses untuk pemodelan masalah real-world speech recognition. Kesuksesan HMM- GMM membuatnya sulit ditandingi oleh algoritma-algoritma baru untuk menyelesaikan masalah yang sama. Satu-satunya kelemahan yang cukup serius adalah HMM-GMM kurang efisien untuk memodelkan data yang terletak atau dekat dengan non-linear manifold pada ruang data (contoh: data berupa titik-titik yang berada dekat dengan permukaan bola (sphere)).

Deep Belief Network - Deep Neural Network (DBN-DNN) adalah arsitektur baru yang merupakan kombinasi dari dua buah arsitektur (DBN dan DNN) di mana arsitektur ini merupakan kombinasi tiga buah Gaussian- Bernoulli Restricted Boltzmann Machines

(GRBMs) yang koneksi antar layer nya dibuat feed-forward mengikuti karakteristik DNN. Saat dilatih dan diuji menggunakan dataset Texas Instruments Massachusetts Institute of Technology (TIMIT), arsitektur deep learning ini ternyata mampu mengalahkan HMM-GMM bahkan dengan margin besar di beberapa pengujian. [18]

3.3.3 Penerjemahan Bahasa

Pada domain penerjemahan bahasa statistik atau Statistical Machine Translation (SMT), pemodelan bahasa menggunakan arsitektur deep learning RNN Encoder-Decoder diajukan sebagai pendekatan baru untuk meningkatkan kinerja pendekatan yang sudah ada yaitu Continuous Space Language Modeling (CSLM). Arsitektur RNN Encoder-Decoder ini terdiri dari dua buah RNN yang memiliki fungsi yang berbeda: encoder dan decoder. RNN Encoder bertugas melakukan encoding simbol sekuensial pada frase yang akan diterjemahkan menjadi bentuk vektor untuk dijadikan input deep learning. Sedangkan RNN Decoder mengembalikan vektor output dari deep learning menjadi simbol sekuensial kembali. Selain itu arsitektur ini juga menggunakan jenis hidden units berbeda yaitu menggunakan activation function yang mirip dengan Long-Short Term Memory (LSTM) dan juga memiliki update gate dan reset gate yang berfungsi untuk membuang (drop) yang kurang relevan dalam proses pembelajaran.[19]. Penelitian lain yang berkaitan dengan pengolahan bahasa adalah [35],[36],[37]

3.3.4 Peringkasan Multi Dokumen

Salah satu kunci dari peringkasan multi dokumen adalah memahami proses komposisi kata-kata menjadi kalimat-kalimat yang menyusun tiap dokumen. Dengan pemahaman terhadap proses tersebut, peringkasan multi dokumen dapat dilakukan secara ekstraktif yaitu dengan memilih sejumlah kalimat yang mewakili seluruh dokumen dengan topik yang sama. Oleh karena itu deep learning dapat digunakan untuk menyelesaikan masalah ini dengan kemampuannya untuk mempelajari komposisi secara otomatis, salah satunya dengan menggunakan stacked Restricted Boltzmann Machines (RBMs).[20]

3.3.5 Prediksi Efek Obat

Salah satu contoh aplikasi deep learning pada bidang bioinformatika adalah pada prediksi efek obat atau Drug Target Interaction (DTI). Prediksi ini dapat digunakan untuk obat yang baru atau sudah lama tidak digunakan untuk meningkatkan efisiensi eksperimen langsung dengan obat dan protein yang notabene sulit dilakukan berulang-ulang dan menghabiskan biaya yang tidak sedikit. Arsitektur deep learning yang diajukan untuk prediksi DTI ini adalah Conditional

Restricted Boltzmann Machine (RBM) dengan dua hidden layers yang dioptimasi bobot jaringannya dengan Contrastive Divergence (CD). Arsitektur ini di-training secara supervised menggunakan dataset MATADOR dan STITCH yang berisi informasi mengenai interaksi antara obat dan protein yang sudah diketahui dan mode of action dari tiap interaksi.

Hasil eksperimen yang dilakukan menunjukkan bahwa algoritma ini mencapai akurasi prediksi (precision- recall) 89.6% yang termasuk cukup akurat dan lebih tinggi dari simple logic approach yang digunakan sebagai pembanding. Hasil eksperimen lain yang dilakukan juga menemukan bahwa hasil prediksi akan meningkat akurasi ketika dimensi interaksi digabungkan (mixed) sebagai input dari RBM (mempertimbangkan mode of action juga). [21]

3.3.6 Prediksi Data Time-Series

Jaringan syaraf tiruan telah lama menjadi solusi pilihan untuk memprediksi nilai masa depan dari sebuah time-series data (contoh: stock market index, foreign exchange rates, electricity consumption rate .dsb). Tapi ada beberapa masalah yang dialami oleh existing approach, yaitu overfitting, initial weights configuration dan optimization learning parameters.

Sebagai salah satu opsi solusi dari masalah yang ada, digunakan arsitektur Deep Belief Network (DBN) yang terdiri dari 3 layers dengan Particle Swarm Optimization (PSO) untuk mencari nilai optimum dari learning parameters (jumlah unit pada visible dan hidden layers, learning rate). Jaringan DBN dioptimasi menggunakan descent probabilities dari fungsi energi aktivasi.[22]

3.3.7 Aplikasi di Perusahaan

Dalam melaksanakan aktivitas suatu perusahaan, diperlukan suatu manajemen yang berguna untuk menerapkan keputusan – keputusan dalam upaya untuk meningkatkan kinerja. Manajemen merupakan salah satu proses yang tidak pernah lepas dari empat, yaitu POAC: planning, organizing, actuating, dan controlling. Demi merealisasikan terlaksananya POAC, perusahaan tidak melakukannya dengan membentuk satu bagian besar, melainkan dengan membaginya ke dalam berbagai bidang dalam menjalankan kegiatan usahanya. Pembagian ini bertujuan untuk memperlancar pencapaian tujuan. Bidang-bidang tersebut misalnya adalah: manajemen produksi, manajemen pemasaran, manajemen keuangan, dan manajemen sumber daya manusia. Agar tujuan perusahaan tercapai maka kinerja dari bidang-bidang tersebut harus optimal. Munculnya teknologi deep learning diharapkan akan banyak membantu

perusahaan untuk mencapai target-target di masing-masing bidang. Bidang sumber daya manusia dapat memilih calon-calon karyawan untuk diseleksi berdasar kriteria-kriteria tertentu dengan menggunakan fungsi klasifikasi pada deep learning, misalnya dengan menggunakan multi layer perceptron . Pada bidang keuangan, dapat diprediksi harga saham bagi perusahaan yang sudah melepas saham ke bursa dengan menggunakan time series deep learning. Bidang pemasaran dapat menangkap suatu produk tertentu menggunakan analisis sentimen berbasis deep learning. [23],[24],[25],[26],[27],[28],[29]

4 Arahan Penelitian Mendatang

Dengan mempertimbangkan penelitian-penelitian dalam area deep learning, beberapa peluang penelitian yang dapat dilakukan adalah:

1. Penentuan jumlah hidden layer dan jumlah neuron yang optimal, karena sampai saat ini penentuan kedua jumlah tersebut belum ada panduan yang mapan
2. Menentukan strategi peningkatan kinerja rantai pasok dengan menggunakan deep reinforcement learning atau recurrent neural network.

5. Referensi

- [1] Wang, J., Ma, Y., Zhang, L., Gao, R. X., & Wu, D. (2018). Deep learning for smart manufacturing: Methods and applications. *Journal of Manufacturing Systems*, 1–13. <https://doi.org/10.1016/j.jmsy.2018.01.003>
- [2] Lecun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444. <https://doi.org/10.1038/nature14539>
- [3] Goodfellow, I., Y. Bengio, et al. (2016). *Deep Learning*, MIT Press.
- [4] Patterson, J., A.Gibson. (2017). *Deep Learning: A Practitioner's Approach*. O'Really.
- [5] Bianchini, M., & Scarselli, F. (2014). On the complexity of neural network classifiers: A comparison between shallow and deep architectures. *IEEE Transactions on Neural Networks and Learning Systems*, 25(8), 1553–1565. <https://doi.org/10.1109/TNNLS.2013.2293637>
- [6] Guo, Y., Liu, Y., Oerlemans, A., Lao, S., Wu, S., & Lew, M. S. (2016). Deep learning for visual understanding: A review. *Neurocomputing*, 187, 27–48. <https://doi.org/10.1016/j.neucom.2015.09.116>
- [7] Hoang, L. N., & Guerraoui, R. (2018). *Deep Learning Works in Practice. But Does it Work in Theory?* Retrieved from <http://arxiv.org/abs/1801.10437>

- [8] Jan, B., Farman, H., Khan, M., Imran, M., Islam, I. U., Ahmad, A., ... Jeon, G. (2017). Deep learning in big data Analytics: A comparative study. *Computers and Electrical Engineering*, 0, 1–13. <https://doi.org/10.1016/j.compeleceng.2017.12.009>
- [9] Li deng. (2014). A tutorial survey of architectures, algorithms, and applications for deep learning. *Sip*, 3(2), 1–29. <https://doi.org/10.1017/ATSIP.2013.99>
- [10] Sze, V., Chen, Y. H., Yang, T. J., & Emer, J. S. (2017). Efficient Processing of Deep Neural Networks: A Tutorial and Survey. *Proceedings of the IEEE*, 105(12), 2295–2329. <https://doi.org/10.1109/JPROC.2017.2761740>
- [11] Zhang, Q., Yang, L. T., Chen, Z., & Li, P. (2018). A survey on deep learning for big data. *Information Fusion*, 42(October 2017), 146–157. <https://doi.org/10.1016/j.inffus.2017.10.006>
- [12] Madhwarasan, M., & Deepa, S. N. (2017). Comparative analysis on hidden neurons estimation in multi layer perceptron neural networks for wind speed forecasting. *Artificial Intelligence Review*, 48(4), 449–471. <https://doi.org/10.1007/s10462-016-9506-6>
- [13] Qolomany, B., Maabreh, M., Al-Fuqaha, A., Gupta, A., & Benhaddou, D. (2017). Parameters optimization of deep learning models using Particle swarm optimization. *2017 13th International Wireless Communications and Mobile Computing Conference, IWCMC 2017*, (Iwcmc), 1285–1290. <https://doi.org/10.1109/IWCMC.2017.7986470>
- [14] Lee, S., Ha, J., Zokhirova, M., Moon, H., & Lee, J. (2018). Background Information of Deep Learning for Structural Engineering. *Archives of Computational Methods in Engineering*, 25(1), 121–129. <https://doi.org/10.1007/s11831-017-9237-0>
- [15] Srivastava, N., G. Hinton, et al. (2014). "Dropout: A Simple Way to Prevent Neural Networks from Overfitting." *Journal of Machine Learning Research*.
- [16] Jindal, I., Nokleby, M., & Chen, X. (2017). Learning deep networks from noisy labels with dropout regularization. *Proceedings - IEEE International Conference on Data Mining, ICDM*, 967–972. <https://doi.org/10.1109/ICDM.2016.124>
- [17] Krizhevsky, A., Sutskever, I. & Hinton, G. ImageNet classification with deep convolutional neural networks. In Proc. Advances in Neural Information Processing Systems 25 1090–1098 (2012).
- [18] Hinton, G. et al. Deep neural networks for acoustic modeling in speech recognition. *IEEE Signal Processing Magazine* 29, 82–97 (2012).
- [19] Cho, K. et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation. In Proc. Conference on Empirical Methods in Natural Language Processing 1724–1734 (2014).
- [20] Zhong, S. et al. (2015). Query-oriented multi-document summarization via unsupervised deep learning. *Expert Systems with Applications* 42 (2015) 8146–8155.
- [21] Zeng, J., Wang, Y. (2013). Predicting drug-target interactions using restricted Boltzmann machines. *Bioinformatics Vol. 29 ISMB/ECCB 2013*, pages i126–i134.
- [22] Kuremoto T. et al. (2014). Time series forecasting using a deep belief network with restricted Boltzmann machines. *Neurocomputing* 137 (2014) 47–56
- [23] Goumagias, N. D., Hristu-Varsakelis, D., & Assael, Y. M. (2018). Using deep Q-learning to understand the tax evasion behavior of risk-averse firms. *Expert Systems with Applications*, 101, 258–270. <https://doi.org/10.1016/j.eswa.2018.01.039>
- [24] Raduški, D. (2016). Basic Management Functions in Culture and Arts Organisations. *Management*, 81, 59–67. <https://doi.org/10.7595/management.fon.2016.0024>
- [25] Krauss, C., Do, X. A., & Huck, N. (2017). Deep neural networks, gradient-boosted trees, random forests: Statistical arbitrage on the S&P 500. *European Journal of Operational Research*, 259(2), 689–702. <https://doi.org/10.1016/j.ejor.2016.10.031>
- [26] Heaton, J. B., Polson, N. G., & Witte, J. H. (2017). Deep learning for finance: deep portfolios. *Applied Stochastic Models in Business and Industry*, 33(1), 3–12. <https://doi.org/10.1002/asmb.2209>
- [27] Lee, J., Jang, D., & Park, S. (2017). Deep learning-based corporate performance prediction model considering technical capability. *Sustainability (Switzerland)*, 9(6), 1–12. <https://doi.org/10.3390/su9060899>
- [28] Paredes-Valverde, M. A., Colomo-Palacios, R., Salas-Zárate, M. P., & Valencia-García, R. (2017). Sentiment Analysis in Spanish for Improvement of Products and Services : A Deep Learning Approach. *Scientific Programming*, 2017, 1–6. <https://doi.org/10.1155/2017/1329281>
- [29] Stockheim, T., Schwind, M., & Wolfgang, K. (2003). A reinforcement learning approach for

- supply chain management. *1st European Workshop on Multi-Agent Systems*.
- [30] Thomas, A. J., Petridis, M., Walters, S. D., Gheytaasi, S. M., & Morgan, R. E. (2016). On predicting the optimal number of hidden nodes. *Proceedings - 2015 International Conference on Computational Science and Computational Intelligence, CSCI 2015*, 565–570. <https://doi.org/10.1109/CSCI.2015.33>
- [31] Thomas, A. J., Walters, S. D., Gheytaasi, S. M., Morgan, R. E., & Petridis, M. (2016). On the Optimal Node Ratio between Hidden Layers: A Probabilistic Study. *International Journal of Machine Learning and Computing*, 6(5), 241–247. <https://doi.org/10.18178/ijmlc.2016.6.5.605>
- [32] Thomas, A. J., Petridis, M., Walters, S. D., Gheytaasi, S. M., & Morgan, R. E. (2017). Two Hidden Layers are Usually Better than One. *Engineering Applications of Neural Networks*, 744, 279–290. <https://doi.org/10.1007/978-3-319-65172-9>
- [33] Thomas, L., Manoj Kumar, M. V., & Annappa, B. (2016). Discovery of optimal neurons and hidden layers in feed-forward Neural Network. *2016 IEEE International Conference on Emerging Technologies and Innovative Business Practices for the Transformation of Societies, EmergiTech 2016*, 286–291. <https://doi.org/10.1109/EmergiTech.2016.7737353>
- [34] Vujičić, T., & Matijević, T. (2016). Comparative Analysis of Methods for Determining Number of Hidden Neurons in Artificial Neural Network. *Central European Conference on Information and Intelligent Systems*, 219.
- [35] Arnab, A., Zheng, S., Jayasumana, S., Romera-Paredes, B., Larsson, M., Kirillov, A., Torr, P. (2018). Conditional Random Fields Meet Deep Neural Networks for Semantic Segmentation. *Ieee Signal Processing Magazine*, XX(Xx), 1–15. Retrieved from <http://www2.maths.lth.se/vision/publdb/reports/pdf/arnab-et-al-2017.pdf>
- [36] Zhang, Q., & Hansen, J. H. L. (2018). Language/Dialect Recognition Based on Unsupervised Deep Learning. *IEEE/ACM Transactions on Audio Speech and Language Processing*, 26(5), 873–882. <https://doi.org/10.1109/TASLP.2018.2797420>
- [37] Hassan, A., & Mahmood, A. (2018). Convolutional Recurrent Deep Learning Model for Sentence Classification. *IEEE Access*, 13949–13957. <https://doi.org/10.1109/ACCESS.2018.2814818>
- [38] Bobkov, D., Chen, S., Jian, R., Iqbal, Z., & Steinbach, E. (2018). Noise-resistant Deep Learning for Object Classification in 3D Point Clouds Using a Point Pair Descriptor. *IEEE Robotics and Automation Letters*, 3(2), 1–1. <https://doi.org/10.1109/LRA.2018.2792681>
- [39] Nie, S., Zheng, M., & Ji, Q. (2018). The Deep Regression Bayesian Network and Its Applications: Probabilistic Deep Learning for Computer Vision. *IEEE Signal Processing Magazine*, 35(1), 101–111. <https://doi.org/10.1109/MSP.2017.2763440>
- [40] Liu, J., Pan, Y., Li, M., Chen, Z., Tang, L., Lu, C., & Wang, J. (2018). Applications of deep learning to MRI images: A survey. *Big Data Mining and Analytics*, 1(1), 1–18. <https://doi.org/10.26599/BDMA.2018.9020001>
- [41] Merchant, K., Revay, S., Stantchev, G., & Nousain, B. (2018). Deep Learning for RF Device Fingerprinting in Cognitive Communication Networks. *IEEE Journal on Selected Topics in Signal Processing*, 12(1), 160–167. <https://doi.org/10.1109/JSTSP.2018.2796446>